

גַּתְנָהָרִים אֶלְעָמֵן כְּלָמָדָה

בְּרֵבָה כְּלָמָדָה

סְבִּירָה כְּלָמָדָה

כְּלָמָדָה בְּרֵבָה

א. ב. ג.

ה. ג. ב. א.

- 1. ג. נ. י.
- 2. ג. נ. י.
- 3. י. ג. נ.

0011001100 ...
10110001101 ...

וְיַעֲשֵׂה אֶת־מִצְרָיִם כְּאֵת כָּל־יְמֵינוֹ וְיַעֲשֵׂה
וְיַעֲשֵׂה אֶת־מִצְרָיִם כְּאֵת כָּל־יְמֵינוֹ וְיַעֲשֵׂה

$\log_2 N$ → 7.232 ≈ 8.5 جمیلیتی

ג'. מה דCCA אומר לגבי מיזוג יתרה וההשפעה על הלקוח?

ה'. מה יקרה אם יתאפשר למכור מזון לאירועים?

$$\binom{h}{m} = \frac{h!}{m!(h-m)!} \quad \textcircled{1}$$

$$\textcircled{2} \quad \log_2 \binom{n}{m} = \log_2 \frac{n!}{m!(n-m)!}$$

$n \gg 1$: Stirling approx $\Rightarrow n! \approx h^n$

$$\approx \log_2 \frac{h^m \cdot h^{n-m}}{m^m \cdot (n-m)^{n-m}} = \log_2 \left[\left(\frac{h}{m}\right)^m \cdot \left(\frac{h}{n-m}\right)^{n-m} \right]$$

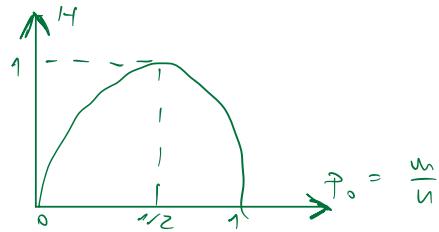
$$= -m \cdot \log_2 \left(\frac{m}{n} \right) - (n-m) \cdot \log_2 \left(1 - \frac{m}{n} \right)$$

$$P_0 = \frac{m}{n}$$

$$\approx n \cdot H(P_0)$$

$$H(P_0) = -P_0 \cdot \log P_0 - (1-P_0) \cdot \log(1-P_0) \quad \leftarrow \text{אנו מודים ב-} H(P_0)$$

$$= n \left[-\frac{m}{n} \cdot \log \left(\frac{m}{n} \right) - \left(1 - \frac{m}{n}\right) \cdot \log \left(1 - \frac{m}{n}\right) \right]$$



... $1-P$ $\log 2^{\text{לפניך}}$ P_0 , P $\log 2^{\text{לפניך}}$, \sqrt{n} n $\log n$
 ... $n > 1$ \rightarrow n $\log n$ \approx $n \cdot \log n$.
 $n \cdot P$ $n \cdot (1-P)$

$$P' = P \text{ (Typical sequence)} = P^n \cdot (1-P)^{n(1-P)}$$

$$P' = 2^{\log P'} = 2^{nP \log P + n(1-P) \log(1-P)} = 2^{-nH(P)}$$

$$\frac{1}{P'} = 2^{nH(P)} \quad \text{בנוסף}$$

$$\text{compression ratio: } \frac{1}{P'} = H(P)$$

Fisher information:

פונקציית פישר מוגדרת כפונקציה של μ

.5

$$X(H) = 1 \quad P(X=1) = P(H)$$

$$X(T) = -1 \quad P(X=-1) = P(T)$$

$$(אנו יונן) \text{ אם } \mu = E\{X\} = P(X=1) \cdot 1 + P(X=-1) \cdot (-1) \rightarrow$$

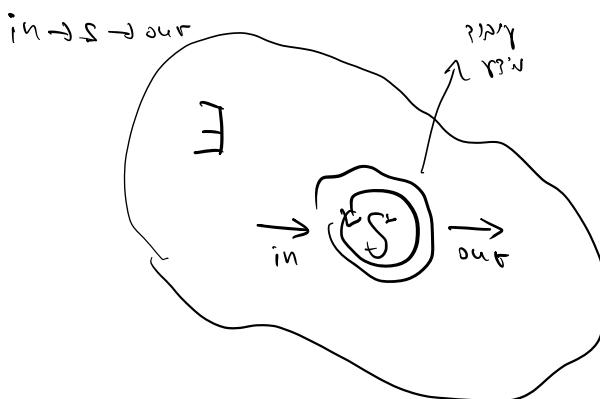
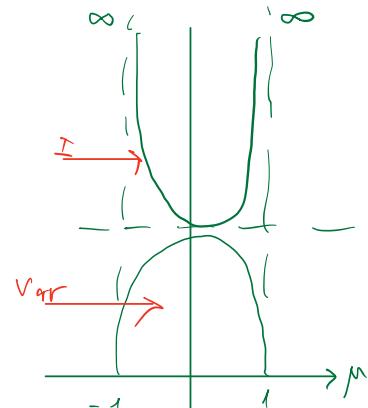
$$\rightarrow P(X=1) = \frac{1}{2}(1+\mu) ; P(X=-1) = \frac{1}{2}(1-\mu)$$

$$= P(X=1) - (1 - P(X=1)) = 2P(X=1) - 1$$

$$I_{\mu}(x) = \frac{1}{Var(x)} \quad (\text{מונע})$$

$$Var(x) = E\{X^2\} - E\{X\}^2 = 1 - \mu^2$$

$$I = -E\left\{\frac{\partial^2}{\partial \mu^2} \log P(X|\mu)\right\}$$



$$P(\text{out} | \text{in}) = \sum_s P(\text{out}|s) \cdot P(s|\text{in})$$

$$\text{סוכנויות} = \int (in)$$

היבטים אינטראקטיביים
in → Sensors out → Actuators

.6

$$I_{\text{out}} \leq I_{\text{in}} \quad : \text{חסוך נול}$$

ב- I_{out} פועל נספח ב- X
 נספח ב- y מושך נספח ב- x
 $? N = E\{X\}$

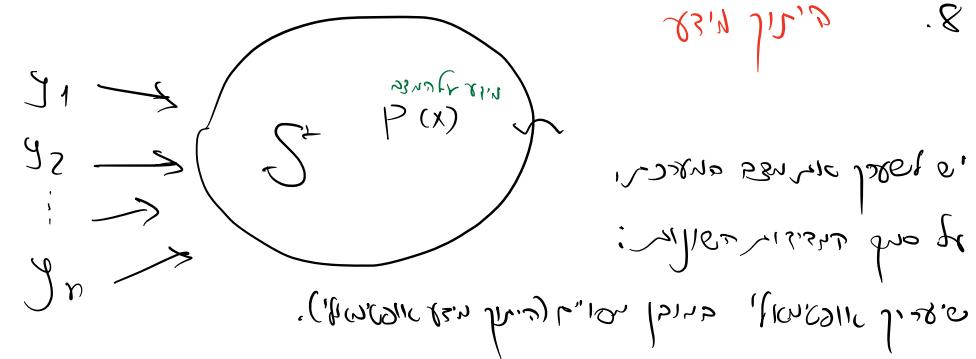
$$\begin{aligned} I_x &= \frac{1}{1-p^2} \\ I_y &=? \end{aligned}$$

$$I_y = -E\left\{\frac{\partial^2}{\partial p^2} \cdot \log P(y|p)\right\}$$

$$\begin{cases} P(x=y|x) = \frac{1}{2} (1+c) \\ P(x \neq y|x) = \frac{1}{2} (1-c) \end{cases}$$

$$\Rightarrow P(y|x) = \frac{1}{2} (1+xy)$$

$$\begin{aligned} P(y=1|p) &= P(y=1|x=1) \cdot P(x=1|p) + P(y=1|x=-1) \cdot P(x=-1|p) \\ &= \frac{1}{2} (1+c) \cdot \frac{1}{2} (1+p) + \frac{1}{2} (1-c) \cdot \frac{1}{2} (1-p) = \frac{1}{2} (1+c)p \end{aligned}$$



$$P(x | y_1, \dots, y_n) \approx P(\text{out} | \text{in})$$

↑ ↑
out in

$$\underset{\substack{\text{预报} \\ \text{输出}}}{x_{n+1}} = f(x_n, u_n, \omega_n) \quad \text{: forecast}$$

↑ ↑
 ω_n
 x_n
 u_n

$$y_{n+1} = h(x_{n+1}, v_{n+1}) \quad \text{: observation}$$

↑
 x_n u_n v_n

x_n u_n v_n \leftarrow u_n, y_n \rightarrow

estimation (prior)

$$P(x_n | y_1, \dots, y_K)$$

Prediction (forecast)

$$P(x_{n+1} | y_1, \dots, y_{n-1})$$

Smoothing (posterior)

$$P(x_{n-\tau} | y_1, \dots, y_n)$$

הנחתה מודולריזציה של מודול טרנסיסטרים. 9

$$P(x_n | y_1, \dots, y_n) = \frac{P(y_1, \dots, y_n | x_n)}{\text{Var}(\tilde{x}_n | y_1, \dots, y_n)} \cdot E\{\tilde{x}_n | y_1, \dots, y_n\}$$

הנחה נוספת שקיים מנגנון סינון בין הפלט:

EKF, UKF, Sequential Monte Carlo.

מבחן דיזל. 10

2	תבונת פיזומטרית
2	תבונת פאראמיטר
2	תבונת נזיר נייד (LSS)
2	תבונת צורה (shape)
1	תבונת מושג (measure)
1	EKF, UKF
2	תבונת מושג (measure)
1	תבונת מושג (measure)
1	תבונת מושג (measure)
1	תבונת מושג (measure)

ו' ג' | קיינס

2 7/80

ט' ג' ס' 1001)

ל' ג' ק' 43 . 1

ו' ג' ק' 2 . 2

ל' ג' 3 . 3

ג' ג' ק' 4 . 4

ל' ג' ק' 5 . 5

ל' ג' ק' 6 . 6

נוסחאות עזר – מבוא להסתברות

$$; A \cup (B \cap C) = (A \cup B) \cap (A \cup C) ; A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

$$\left(\bigcap_i \overline{A_i} \right) = \overline{\left(\bigcup_i A_i \right)} \quad \left(\bigcup_i \overline{A_i} \right) = \overline{\left(\bigcap_i A_i \right)}$$

הוקי הפילוג: $A \cap B = \emptyset$ אם A, B מאורעות זרים

הוקי דה מורגן:

סדרת מאורעות תקרה זרים בזוגות אם כל זוג מאורעות מותוכה הם זרים.

$$P\{A\} = P\{A \cap B\} + P\{A \cap \bar{B}\}$$

$$P\{\bar{A}\} = 1 - P\{A\}$$

$$P\{A \cup B\} = P\{A\} + P\{B\} - P\{A \cap B\}$$

$$P\left\{ \bigcup_{i=1}^n A_i \right\} = \sum_{i=1}^n P\{A_i\}$$

אם סדרת מאורעות זרים בזוגות אז $\{A_i\}_{i=1}^n$:

נוסחת הכללה וההוצאה (inclusion exclusion):

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$$

$$P(A \cup B \cup C \cup D) = P(A) + P(B) + P(C) + P(D) -$$

$$- P(A \cap B) - P(A \cap C) - P(A \cap D) - P(B \cap C) - P(B \cap D) - P(C \cap D) +$$

$$+ P(A \cap B \cap C) + P(A \cap B \cap D) + P(B \cap C \cap D) - P(A \cap B \cap C \cap D)$$

כללים קומבינטוריים:

כל המכפלה: אם ניסוי נתן להצגה כמתבצע ב k שלבים, ובשלב k יש n_k תוצאות אפשריות וסימטריות, ואם מרחב המדגם מוגדר כוקטורים באורך k כאשר הרכיב i שלו הוא תוצאה שלב i , אז במרחב המדגם יש $n_1 \cdot n_2 \cdot \dots \cdot n_k$ תוצאות אפשריות סימטריות.

מספר האפשרויות לדגימה של k מתוך n איברים:

ללא התחשבות בסדר	התחשבות בסדר הדגימה	
(מרחב מודגם לא סימטרי)	n^k	עם החזרה
$\binom{n}{k} = \frac{n!}{k!(n-k)!}$	$\frac{n!}{(n-k)!}$	ללא חזרה

$$P\{A \cap B\} = P\{A\}P\{B / A\}, P\{A / B\} = \frac{P\{A \cap B\}}{P\{B\}}$$

הסתברות מותנית:

נוסחת ההסתברות השלמה:

$$P\{A\} = \sum_{i=1}^n P\{A / B_i\}P\{B_i\}$$

אם $\{B_i\}_{i=1}^n$ חלוקה של מרחב המדגם, אז:

$$P(A) = \sum_{i=1}^n P\{A / B_i\}P\{B_i\} \quad \text{כאשר: } P\{B_k / A\} = \frac{P\{A / B_k\}P\{B_k\}}{P\{A\}}$$

נוסחת בייס:

אי תלות: A ו B הם מאורעות **בלתי תלויים** אם מתקיים: $P\{A / B\} = P(A)$ או $P\{A \cap B\} = P(A)P(B)$.
קבוצת מאורעות הם **בלתי תלויים** אם כל קבוצה חילקית שלהם מקיימת שהסתברות החיתוך שלהם שווה למינימום ההסתברויות.

סדרת ניסויי ברנולי: סדרת ניסויים זהים ובלתי תלויים, שבו כל ניסוי שתי תוצאות אפשריות: הצלחה וכשלון, כאשר ההסתברות להצלחה בניסוי בודד היא p .

משתנים מקרים:

משתנה מקרי בדיד: פונקציית ההסתברות: $P(X = k) = P(X \leq k)$ פונקציית ההסתברות המצחכרת: $E[g(X)] = \sum_k g(k) \cdot P\{X = k\}$; התוחלת של פונקציה של X , $E[X] = \sum_k k \cdot P\{X = k\}$; השונות של X : $\sigma^2[X] = V[X] = E[(X - E(X))^2] = E[X^2] - (E[X])^2$; סטיית התקן של X : $V[X] = E[(X - E(X))^2] = E[X^2] - (E[X])^2$; השכיח הוא הערך בעל ההסתברות הגבוהה ביותר, החציון הוא הערך בו $F(x)=0.5$

משתנים (בדידים) מיוחדים:

אחד (בדיד): מתאר משתנה המקבל את הערכים: $N, 1, 2, \dots, N$, בהסתברויות שוות.

$$P\{X = k\} = \frac{1}{N} \quad k = 1, 2, \dots, N; \quad E[X] = \frac{N+1}{2}; \quad V[X] = \frac{N^2 - 1}{12}$$

עבור משתנה זה:

בינומי: $X \sim B(n, p)$, מתאר את מספר ההצלחות ב- n ניסויי ברנולי.

$$P\{X = k\} = \binom{n}{k} p^k q^{n-k} \quad k = 0, 1, \dots, n; \quad E[X] = np; \quad V[X] = npq$$

עבור משתנה זה:

גיאומטרי: $X \sim G(p)$, מתאר את מספר הניסויים עד להצלחה (כולל) בסדרת ניסויי ברנולי.

$$P(X = k) = pq^{k-1} \quad k = 1, 2, \dots; \quad P(X \leq k) = 1 - q^k \quad k = 1, 2, \dots; \quad E[X] = \frac{1}{p}; \quad V[X] = \frac{q}{p^2}$$

היפרגיאומטרי: $X \sim H(N, R, n)$: מתאר את מספר האיברים המיוחדים שיתקבלו בבחירה n איברים ללא החזרה מאוכלוסייה בגודל N שבה R איברים מיוחדים.

עבור משתנה זה:

$$P\{X = k\} = \frac{\binom{R}{k} \binom{N-R}{n-k}}{\binom{N}{n}} \quad k = 0, 1, 2, \dots, n; \quad E(X) = n \frac{R}{N}; \quad V(X) = n \frac{R}{N} \frac{(N-R)}{N} \frac{(N-n)}{(N-1)}$$

פואסוני: $X \sim Pois(\lambda)$, משמש בדרך כלל לתיאור מספר אירועים בתחום מסווגדר.

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \quad k = 0, 1, 2, \dots; \quad E(X) = V(X) = \lambda$$

עבור משתנה זה:

משתנה מקרי רציף: פונקציית הצפיפות: $f(x)$, פונקציית ההסתברות המצחכרת:

$$F(t) = P\{X \leq t\} = \int_{x=-\infty}^t f(x) dx$$

התוחלת של X : $E[X] = \int g(x)f(x)dx$; **התוחלת של פונקציה של X :** $E[g(X)] = \int g(x)f(x)dx$

השונות של X : $\sigma^2[X] = V[X] = E[(X - E(X))^2] = E[X^2] - (E[X])^2$; **סטיית התקן של X :** $V[X] = E[(X - E(X))^2] = E[X^2] - (E[X])^2$

השכיח הוא הערך בו הצפיפות היא מקסימלית, החציון הוא הערך בו $F(x)=0.5$

משתנים (רציפים) מיוחדים:

אחד (רציף): $X \sim U(a, b)$ מתאר משתנה המקביל ערכים בין a ל- b כך שהסתברות לערך בקטע פרופורצионаלית לאורך הקטע.

$$f(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{elsewhere} \end{cases}; \quad F(x) = \begin{cases} 0 & x \leq a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x \geq b \end{cases}; \quad E(X) = \frac{a+b}{2}; \quad V(X) = \frac{(b-a)^2}{12}$$

עבור משתנה זה :

מעריצי (אקספוננציאלי): $X \sim \text{exp}(\lambda)$, משמש בדרך כלל לתיאור אורך חי רכיבים ומערכות אלקטרוניות.

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}; \quad F(x) = \begin{cases} 0 & x \leq 0 \\ 1 - e^{-\lambda x} & 0 \leq x \end{cases}; \quad E(X) = \frac{1}{\lambda}; \quad V(X) = \frac{1}{\lambda^2}$$

עבור משתנה זה :

נורמלי : $X \sim N(\mu, \sigma^2)$, משמש לצרכים רבים....

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad -\infty \leq x \leq \infty; \quad E(X) = \mu; \quad V(X) = \sigma^2$$

עבור משתנה זה :

чисוב הסתברויות עבור משתנה זה בעזרת טבלת התפלגות המצטברת של המשתנה הסטנדרטי

$$P\{X \leq t\} = P\{Z \leq \frac{t-\mu}{\sigma}\} = \Phi\left(\frac{t-\mu}{\sigma}\right) \quad \text{והчисוב מתבצע על ידי : } Z = \frac{X-\mu}{\sigma} \sim N(0,1)$$

את הערך (t) קוראים בטבלה, הוא מקיים :

$$\Phi(-a) = 1 - \Phi(a)$$

משתנה דו ממדי בדיד: פונקציית ההסתברות המשותפת :

$$P_X(k) = P\{X = k\} = \sum_j P\{X = k, Y = j\}$$

פונקציית ההסתברות השולית של X :

$$P_{X/Y}(k/j) = P\{X = k / Y = j\} = \frac{P\{X = k, Y = j\}}{P\{Y = j\}}$$

פונקציית ההסתברות המותנית של X בהינתן j :

שני משתנים : X, Y יקראו **בלתי תלויים** אם $P_{X,Y}(x_i, y_j) = P_X(x_i)P_Y(y_j)$ לכל הערכים האפשריים i, j .

משתנה דו ממדי רציף: פונקציית הצפיפות המשותפת :

$$f_X(x) = \int f_{X,Y}(x, y) dy$$

פונקציית הצפיפות השולית של X :

$$f_{X/Y}(x/y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

פונקציית הצפיפות המותנית של X בהינתן y :

שני משתנים : X, Y יקראו **בלתי תלויים** אם $f_{X,Y}(x, y) = f_X(x)f_Y(y)$ לכל הערכים האפשריים x, y

תכונות התוחלת והשונות: $E[aX + b] = aE[X] + b$; $V[aX + b] = a^2V[X]$

$$E\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n E[X_i]; \quad V\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n V[X_i] + \sum_{i \neq j}^{n^2-n} Cov(X_i, X_j)$$

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y); \quad \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

$$\text{Cov}(aX + b, Y) = a\text{Cov}(X, Y); \quad \text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$$

$$S_N = \sum_{i=1}^N X_i; \quad E[S_N] = E[N]E[X]; \quad V[S_N] = E[N]V[X] + V[N]E^2[X]$$

סכום מקרי של משתנים מקריים:

נוסחת התוחלת השלמה:

$$E[X] = \sum_j E(X / Y = j) P\{Y = j\} = \sum_j E(X / B_j) P\{B_j\}$$

מבחן מקרי פשוט הוא אוסף של מ"מ בלתי תלויים, לכולם אותה התפלגות.

$$E[\bar{X}_n] = E[X] ; V[\bar{X}_n] = \frac{V[X]}{n} \text{ והוא מקיים: } \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

אי שוויוניים וחוקי גבול:

אי שיוון מركוב: אם X משתנה מקרי אי שלילי ولو תוחלת $E[X]$ או קיים:

אי שיוון צ'בישב: אם X משתנה שלו תוחלת $E[X]$ ושונות $(X) \geq t^2$ אז קיים:

(ה)חוק (החלש של) המספריות הגזוליות: כאשר n שואף לאינסוף, ממוצע המבחן שואף לתוחלת המשתנה.

משפט הגבול המרכזי: עבור מבחן מקרי פשוט קיים, עבור n מספיק גדול ($n \geq 30$) אם X משתנה מקרי עם תוחלת $\mu = E(X)$ ושונות $\sigma^2 = V(X)$ אז:

$$\bar{X}_n \sim N(\mu, \frac{\sigma^2}{n})$$

$$\sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2)$$

קרוב נורמלי למשתנה בינומי: עבור X משתנה בינומי: $X \sim B(n, p)$ כאשר n מספיק גדול, כך ש: $np > 5$ ו גם: $nq > 5$, מתקיים:

$$P\{X \leq k\} = \Phi\left(\frac{k + 0.5 - np}{\sqrt{npq}}\right) ; P\{X < k\} = \Phi\left(\frac{k - 0.5 - np}{\sqrt{npq}}\right)$$

תיקון רציפות:

אינטואיטיבי

. A תולן למשרר מוגדר η_A כפונקציית נסיגה: $\eta_A : \text{לוכט'} \rightarrow [0, 1]$

$$P(A) = \lim_{n \rightarrow \infty} \left(\frac{\eta_A}{n} \right)$$

: נסיגת



? מושג הילוב של סדרה של n נסיגות כפנויות. נסיגת ה- i-הה היא נסיגת ה- i-הה בוקס. 1

לנסיגת הילוב של סדרה של n נסיגות כפנויות. נסיגת ה- i-הה היא נסיגת ה- i-הה בוקס. 2
? מושג הילוב של סדרה של n נסיגות כפנויות.

: נסיגת

$$P(\text{ילוב}) = \sum_{i=1}^n P(\text{ילוב} | b_i) \cdot P(b_i) = \frac{1}{n} \sum_{i=1}^n P(\text{ילוב} | b_i) = \frac{1}{n} \sum_{i=1}^n \frac{s_i}{s_i + r_i} . 1$$

$$P(b_m | \text{ילוב}) = P(\text{ילוב} | b_m) \cdot P(b_m) = \frac{s_m}{s_m + r_m} \cdot \cancel{\frac{1}{n}} . 2$$

$$\cancel{\frac{1}{n}} \sum_{i=1}^n \frac{s_i}{s_i + r_i}$$

שאלה וריאציה

נ'ל'ג' נ'ל'ג' ה'ל'ג' נ'ל'ג' נ'ל'ג' .

1. נ'ה ה'ל'ג' ה'ל'ג' ?
 2^{-n} ?

2. נ'ה ה'ל'ג' ה'ל'ג' ?
 2^{-n} ?

3. נ'ה ה'ל'ג' ה'ל'ג' ?
 $\binom{m}{n} 2^{-n}$?

4. נ'ה ה'ל'ג' ה'ל'ג' ?
 $1/2$?

$\{\emptyset\}$, $\{i \in A, j \notin A\}$, $A = \{\{1, 2, \dots, n\}\}$:

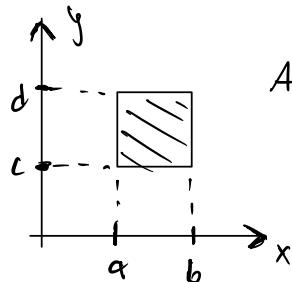
- Lösung

$$A = \{1, 2, 3\} \longrightarrow \{\emptyset\}$$

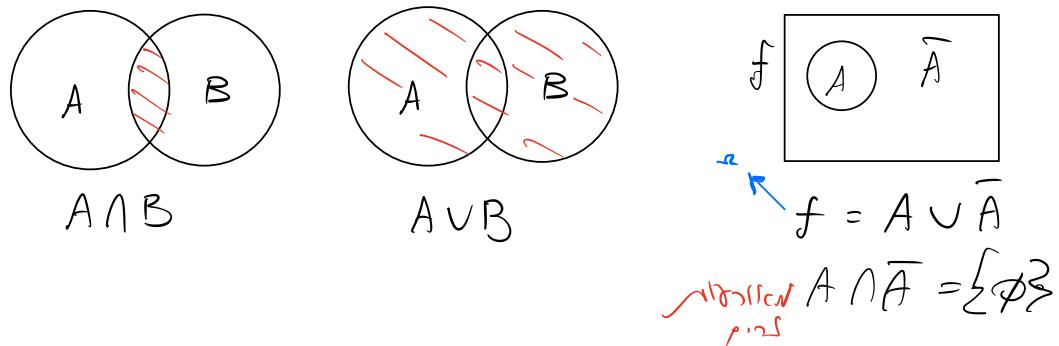
ר'ע'ל'ג' ה'ל'ג' $\rightarrow |A|$

$$2^{|A|} = 2^3 = \{1, 2, 3\}$$

$$\begin{aligned} &\{1\}, \{2\}, \{3\} \\ &\{1, 2\}, \{2, 3\}, \{1, 3\} \\ &\{1, 2, 3\} \end{aligned}$$



$$\begin{aligned} A &= \{(x, y) \mid a \leq x \leq b, c \leq y \leq d\} \\ &= \{(x, y) \mid a \leq x \leq b \wedge c \leq y \leq d\} \end{aligned}$$



$$\text{אנו ר' } A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

- Lenor

$$\begin{aligned} A &= \{1, 2, 3, 4, 5, 6\} \\ B &= \{\text{even}\}, \quad \bar{B} = \{\text{odd}\} \\ A \cap B &= \{2, 4, 6\} \end{aligned}$$

ולפניהם נסמן.

: מושג. אוסף כלים במרחב נקרא - סט

$$S = \{1, \dots, 6\} \quad \text{הו אוסף סט}$$

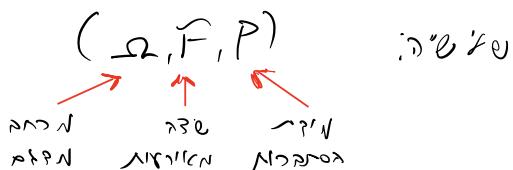
$$S = \{H, T\} \quad \text{抛硬币的样本空间}$$

: מושג. $P = 2^S$ דהיינו סט - F

$$F = 2^6 = 64 \quad \text{抛硬币6次的样本空间}$$

$$F = 2^2 = 4 \quad \text{抛硬币2次的样本空间}$$

: מושג P - P



$$1. P(A) \geq 0 \quad 2. P(S) = 1$$

$$3. A \cap B = \{\emptyset\} \xrightarrow{\text{ר' }} P(A \cup B) = P(A) + P(B)$$

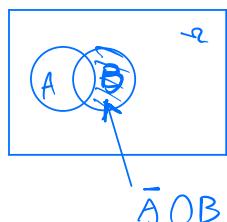
הוכיחו

$$P(A \cup B) = ?$$

הוכיחו

$$B = B \cap \Omega = B \cap (A \cup \bar{A}) = (B \cap A) \cup (B \cap \bar{A})$$

$$\left\{ \begin{array}{l} P(B) = P(B \cap A) + P(B \cap \bar{A}) \\ P(A \cup B) = P(A) + P(\bar{A} \cap B) \end{array} \right.$$



$$A \cup B = A \cup (\bar{A} \cap B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \leq P(A) + P(B)$$

הוכיחו

$$\Omega = \{1, 2, \dots, 6\}$$

- גורם נסובן

$$P(i) = 1/6, \quad i = 1, \dots, 6$$

$$P(\Omega) = \sum_{i=1}^6 P(i) = 1$$

? 6ilo 1 מינימום שגורה הוא .1

? 6-1 1 מינימום שגורה הוא .2

? 5 = מינימום שגורה שגורה. מינימום שגורה הוא .3

הנחות: גורם נסובן

הנחות

$$1. P(\{1\} \cup \{6\}) = P(1) + P(6) = \frac{1}{6} + \frac{1}{6} + \frac{1}{3}$$

$$2. P(\{1\} \cap \{6\}) = 0$$

$$3. \Omega_1 \times \Omega_2 = \{1_1, 1_2, \dots, 1_6, 2_1, \dots, 2_6, 6_1, \dots, 6_6\}$$

$$P(i_1 \cup j_2) = P_1(i_1) \cdot P_2(j_2)$$

$$A = \left\{ \begin{smallmatrix} i+j=5 \\ i,j \in \{1,2,3,4\} \end{smallmatrix} \right\} = \{1_4, 4_1, 2_3, 3_2\} \rightarrow P(A) = 4/36 = 1/9$$

(ז' מ') - כוכב ר' ירושם ר' ירושם.

$$P[(i_1, \dots, i_n) \in \Omega_1 \times \dots \times \Omega_n] = P(i_1 \in \Omega_1) \cdot \dots \cdot P(i_n \in \Omega_n)$$

$$F = \sum_{1 \times 2 \times \dots \times n} \alpha_1 \times \dots \times \alpha_n$$

אנו מוגבלים ל-

$$\Omega = \mathbb{R}$$

$$F = \left\{ \begin{array}{l} \text{אינטגרציה} \\ \text{ב}[a,b] \end{array} \right\}$$

$$\int_{-\infty}^{\infty} \alpha(x) dx = 1 \quad , \quad \alpha(x) > 0$$

$$P(-\infty, \infty] = \int_{-\infty}^{\infty} \alpha(x) dx$$

$$P([w_1, w_2]) = \int_{w_1}^{w_2} \alpha(x) dx$$

$$P(x \in w_1) = \lim_{w_2 \rightarrow w_1} \int_{w_1}^{w_2} \alpha(x) dx = 0$$

5. תורת המסתור

$$P(A|M) \triangleq \frac{P(A \cap M)}{P(M)}$$

(? נרמז M כSubset של מenge א) ו $P(M)$ כהסתור א

לונדרס

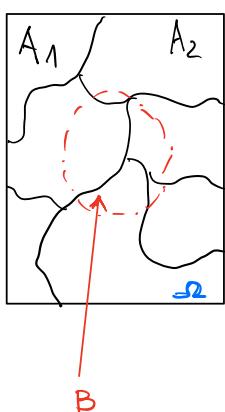
$$A = \{2, 3\}, M = \{1, 2, 3\}$$

- נספחים

$$\underline{P(\{2, 3\} \cap \{1, 2, 3\})} \quad \underline{P(2)} = \underline{\frac{1}{6}} = \underline{\frac{1}{3}}$$

$$P(A|M) = P(\{2, 3\}) = P(2, 3) = \frac{2}{6} = \frac{1}{3}$$

(Total probability) הסתור הכולל . 6



$$B = B \cap \Omega = B \cap (\bigcup_{i=1}^n A_i) = \bigcup_{i=1}^n (A_i \cap B)$$

$$P(B) = \sum_{i=1}^n P(A_i \cap B)$$

הסתור הכולל = $\sum P(B|A_i) \cdot P(A_i)$

: | ✓

$$P(B) = \sum_{i=1}^n P(B|A_i) \cdot P(A_i)$$

: o"n ላ

$$P(A_i|B) = \frac{P(B|A_i) \cdot P(A_i)}{\sum_{j=1}^n P(B|A_j) \cdot P(A_j)}$$

ת. 10.1 אוניברסיטה

• סדרה רציפה של ניסויים נספחים. P נקראת הסתברות ניסוי מושג בפעם הראשונה. n ניסויים מושגים מ- m ניסויים מושגים מ- n .

$$P(\text{מושגים } m) = \binom{n}{m} p^m \cdot (1-p)^{n-m} = \frac{n!}{m!(n-m)!} p^m \cdot (1-p)^{n-m}$$

ו' ו' | ו' ו'

ו' ו' ו' ו'

: ו' ו' ו' ו'

1. ו' ו' ו' ו'
2. ו' ו' ו' ו'
3. ו' ו' ו' ו'
4. ו' ו' ו' ו'

$$\begin{array}{c} \text{ווריאנט נסיעה} \\ \text{נישגון אונ} \\ h \cdot q \end{array}$$

$$t \in [h \cdot q] + 1$$

~~לפיכך מתקבל~~

נוסף זה מוגדרת הופא כפיע:

$$(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k} \quad (1) \quad -\text{DR}$$

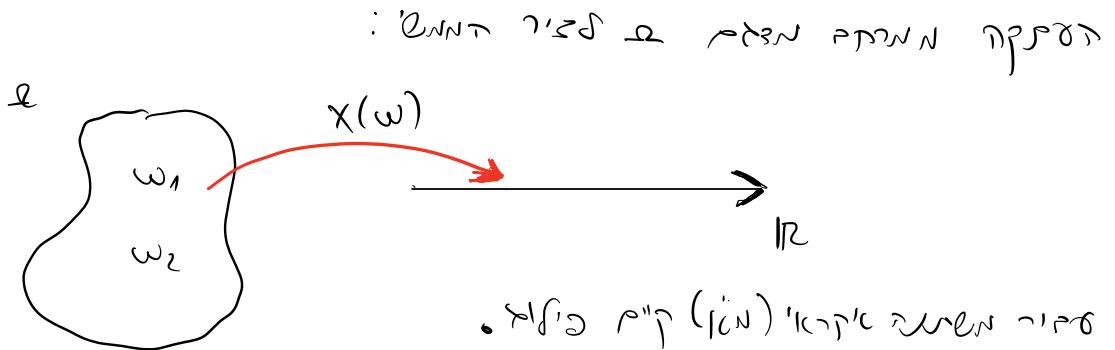
$$\begin{aligned} Q(t) &\stackrel{\Delta}{=} \sum_{k=0}^n q^{t-k \log(q)} \binom{n}{k} q^k (1-q)^{n-k} \\ &= \sum_{k=0}^n q^{(t \cdot \log(q) + 1)k} (1-q)^{n-k} \cdot \binom{n}{k} \end{aligned} \quad -\text{רמז} \quad (1) \quad \text{ה''ר}$$

$$= \left[1 - q + q^{t \log(q) + 1} \right]^n = \left[1 - q + q e^t \right]^n$$

$$\frac{\partial}{\partial t} Q(t) \Big|_{t=0} = \frac{\partial}{\partial t} \left[1 - q + q e^t \right]^n \Big|_{t=0}$$

$$= n \cdot q \cancel{e^t} \left[1 - q + q \cancel{e^t} \right]^{n-1} = \underline{\underline{n \cdot q}}$$

Random Variables - מ�וקם רנדום



$$X(H) = 1$$

$$X(T) = -1$$

למשל: סיבוב כדור

$$i = 1, \dots, 6$$

$$X(i) = -10i$$

$$P(\{X \leq \infty\}) = 1$$

$$P(X = \pm \infty) = 0$$

נתקיימת כפלה:

$$F_x(X) \triangleq P(x \leq X)$$

- פונקציית

$$F_x(5) = P(x \leq 5)$$

- ICN 8/3

$$\chi(h) = 1$$

: random variable

$$\chi(T) = 0$$

- 1/2

$$P(x) = 1 = P(h) \triangleq q$$

$$P(x=0) = P(T) = 1-q$$

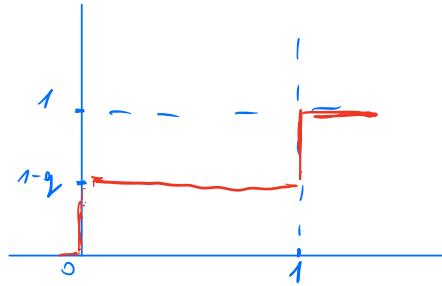
$$F_x(x)$$

$$F_x(-\infty) = 0$$

$$F_x(0) = P(x \leq 0) = 1-q$$

$$F_x(1) = P(x \leq 1) = P(\{x=0\} \cup \{x=1\}) = P(x=0) + P(x=1) = 1$$

$$F_x(\infty) = 1$$



ריבועי ייון - סטטיסטיקה

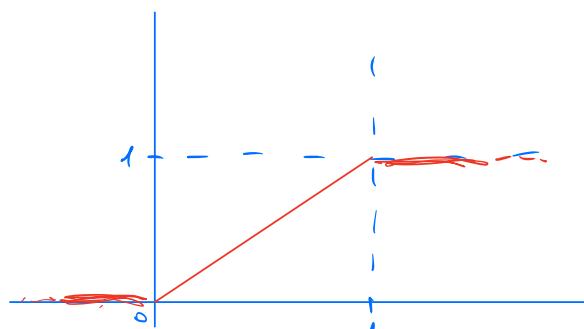
- ICN 8/3

$$\chi(t) = t \quad 0 \leq t \leq 1$$

$$P(t_1 \leq x \leq t_2) = t_2 - t_1$$

$$F_x(t_1) = P(x \leq t_1) = t_1$$

$$F_x(t) = t$$



כלייר על כל אטג'ה:

$$1. \quad F(+\infty) = 1$$

$$F(-\infty) = 0$$

$$2. \quad a \leq b$$

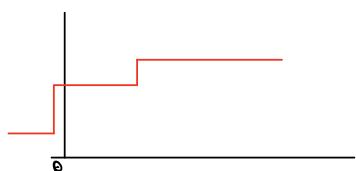
$$\rightarrow F(a) \leq F(b)$$

$$3. \quad P(X \geq w) = 1 - F_X(w)$$

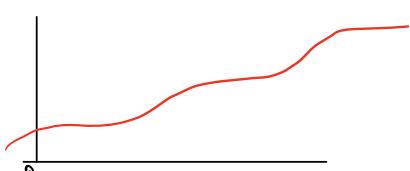
$$4. \quad P(w_1 \leq X \leq w_2) = F_X(w_2) - F_X(w_1)$$

לעתה נזכיר, מילא קבוצת כל אחד!

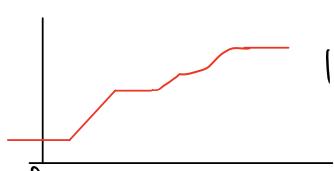
כל אחד קבוצה אחת:



1. פונקציית סטפס.



2. פונקציית רציפה.



3. פונקציית קו ישרים.

פונקציית הצפיפות $f_x(x)$ היא פונקציה סכיפה:

$$f_x(w) \triangleq \frac{\partial F_x(x)}{\partial x} \Big|_{x=w}$$

$f_x(w) \geq 0$ ו- $\int f_x(x) dx = 1$

$$F_x(w) = \int_{-\infty}^w f_x(x) dx \quad .2$$

$$\int_{-\infty}^{\infty} f_x(x) dx = F_x(+\infty) = 1 \quad .3$$

$$\int_{x_1}^{x_2} f_x(x) dx = F_x(x_2) - F_x(x_1) = P(x_1 \leq x \leq x_2) \quad .4$$

$$\int_w^{w+\Delta w} f_x(x) dx \approx f_x(w) \cdot \Delta w \approx P(x \in [w, w+\Delta w]) \quad .5$$

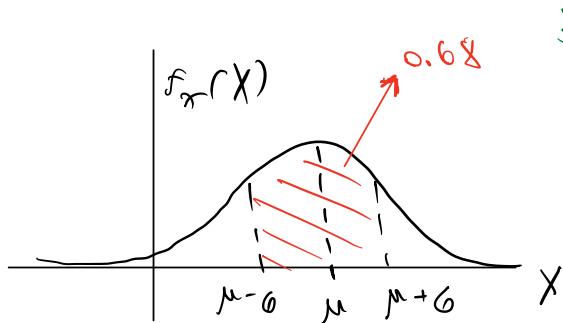
3. גודל נורמל סטנדרטי / צמיגן.

$x \in \mathbb{R}$

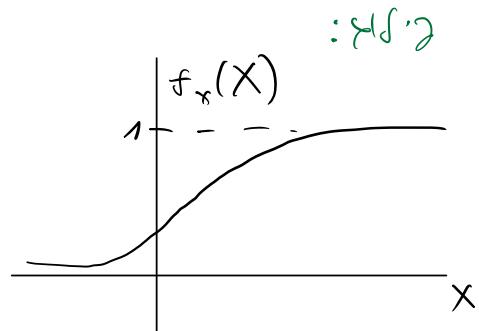
$$f(x) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi} \cdot \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$P(\mu - \sigma \leq x \leq \mu + \sigma) \approx 0.68$$

הטפלת נורמלית בדעת!

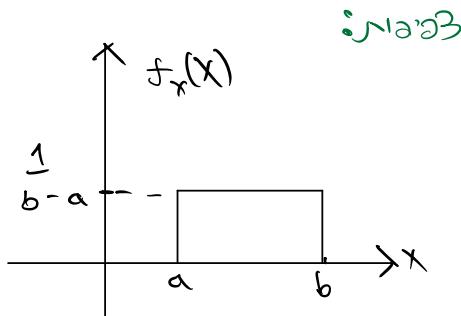


בבבב:

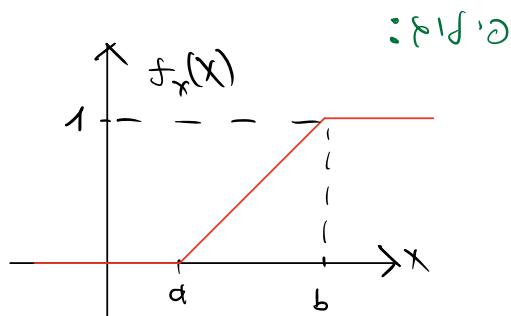


2. מילוי / פולינום.

$$\begin{cases} f_x(x) = \frac{1}{b-a}, & a \leq x \leq b \\ f_x(x) = 0, & x < a, \quad x > b \end{cases}$$



בבבב:



בבבב:

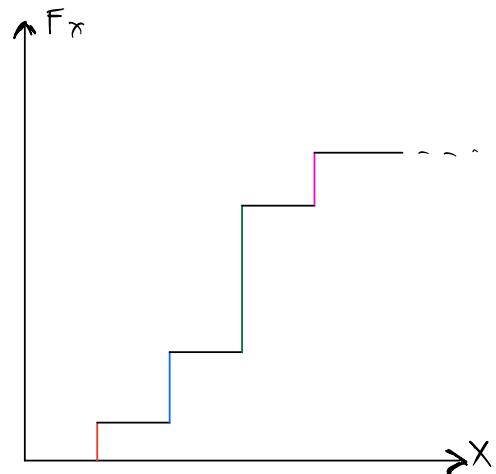
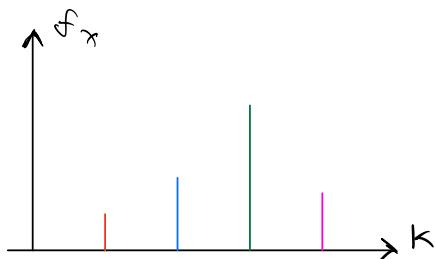
וילנא 3

$$f_x(k) = \binom{n}{k} q^k (1-q)^{n-k} \cdot P(x=k)$$

$$F_x(x) = \int_{-\infty}^x f_x(x) dx = \sum_{k=0}^x \binom{n}{k} q^k (1-q)^{n-k}$$

P(x=k)

כיאו: דכיאו:



וילנא 4

$$F_x(x|\mu) \triangleq P(x \leq X | \mu) = \frac{P(\{x \leq X\} \cap \mu)}{P(\mu)}$$

וילנא $f_x(x|\mu) \rightarrow$ מילאנו מילאנו

- $F_{X \sim U(1,6)}$

נניח ש�ודם נסובב ב- Ω , וקיים אובייקט x .

- $F_x(x)$

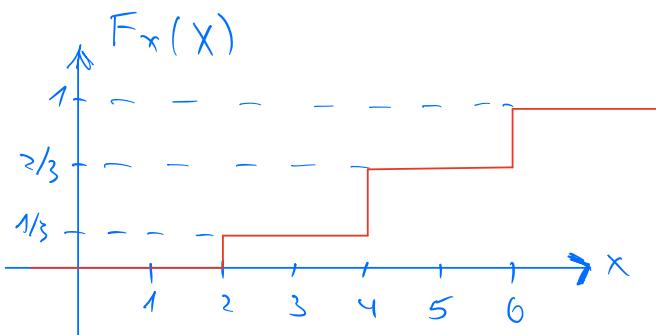
$$P(X=i) = 1/6, \quad i=1, \dots, 6.$$

$$F_x(X \in \{x\}) = \frac{P(\{x \leq X\} \cap \{x\})}{P(\{x\})} = \frac{P(\{x \leq X\} \cap \{x\})}{P(\{2,4,6\})}$$

$$F_x(1 \mid \{x\}) = 0$$

$$F_x(2 \mid \{x\}) = \frac{P(\{x \leq 2\} \cap \{2,4,6\})}{P(\{2,4,6\})} = \frac{P(2)}{P(\{2,4,6\})} = \frac{1/6}{3/6} = \frac{1}{3}$$

$$F_x(6 \mid \{x\}) = \frac{P(\{x \leq 6\} \cap \{2,4,6\})}{P(\{2,4,6\})} = \frac{P(\{2,4,6\})}{P(\{2,4,6\})} = 1$$



- ICN&12

$$a \leq x \leq b$$

$$c \leq x < d$$

. י"offer יוגר עמלן ג נ

נפ הנטרנילר ו-

כונטן יבג כי -

- ICN&12

$$P(a \leq X \leq b | c \leq X \leq d) = \int_a^b f_x(X | c \leq X \leq d) dx \quad (4) f_3 \text{ in ICN}$$

$$= F_x(b | c \leq X \leq d) - F_x(a | c \leq X \leq d)$$

$$\text{DEFINITION } F_x(X | c \leq X \leq d) = \frac{P(\{x \leq X\} \cap \{c \leq X \leq d\})}{P(\{c \leq X \leq d\})} \quad \text{ר'ב'ג}$$

$$F_x(X | c \leq X \leq d) = \begin{cases} 0, & x < c \\ \frac{F_x(d) - F_x(c)}{P(\{c \leq X \leq d\})}, & c \leq X \leq d \\ 1, & x > d \end{cases}$$

ר' מילר מורה.

אם $F_x(X) = P(x \leq X) = \sum_i P(x \leq 0 | A_i) \cdot P(A_i)$

ו $f_x(x) = \sum_i f_x(x | A_i) \cdot P(A_i)$

- VNZ

- G_1, M_1 הם נספחים, היות שמה נספחים זרים
- G_2, M_2 הם נספחים נזירים וקיים שפה נספחים זרים

1. מה הטענה שקיימת נספחה הינה?
שיהי נספחה הינה?
2. מה הטענה שקיים $[a, b]$ שפה נספחים זרים?

- 125

1. $P(x = a) = 0$ אם כי בפניהם נספחים:

2. $P(a < x \leq b) = \int_a^b f_x(x) dx$

$$q \cdot f_x(x | G_1, M_1) + (1-q) \cdot f_x(x | G_2, M_2) =$$

$$= q \cdot N(x | \mu_1, \sigma_1^2) + (1-q) \cdot N(x | \mu_2, \sigma_2^2)$$

$P(a < x < b) = q \cdot P(a < x \leq b | G_1, M_1) + (1-q) \cdot P(a < x \leq b | G_2, M_2)$

~~ANSWER~~ .5

$$\begin{aligned} P(A | x \leq X) &= \frac{P(x \leq X | A) \cdot P(A)}{P(x \leq X)} \\ &= \frac{F_x(X | A) \cdot P(A)}{F_x(X)} \end{aligned}$$

$$f_x(X | A) = \frac{P(A | x=X) \cdot f_x(X)}{P(A)}$$

וְיַעֲשֵׂה

וְיַעֲשֵׂה

: הַמִּזְבֵּחַ וְיַעֲשֵׂה

- 1. אֶלְעָזֶר כָּל נָעָם וְאֶלְעָזֶר
- 2. אֶלְעָזֶר הַמִּזְבֵּחַ וְאֶלְעָזֶר
- 3. אֶלְעָזֶר הַמִּזְבֵּחַ

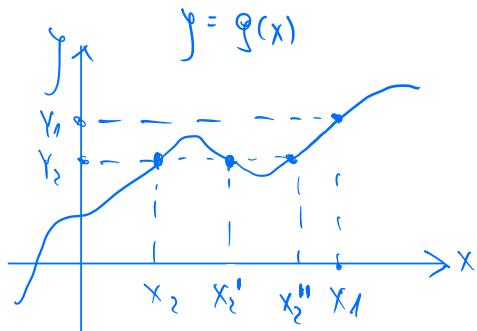
לע'ן $F_x(x)$, $f_x(x)$

לע'ן y מוגדרת כפונקציית.

y , $f(y)$

לע'ן x מוגדרת כפונקציית y מוגדרת כפונקציית x

? $f_x(x) = \frac{y}{x}$ ————— y ————— x



$$F_y(Y) = P(\{y \leq Y\}) = P(f(g(x)) \leq Y)$$

$$\begin{aligned} F_y(Y_1) &= P(\{y \leq Y_1\}) = P(\{g(x) \leq Y_1\}) = \\ &= P(x \leq X_1) = F_x(X_1) = F_x(g^{-1}(Y_1)) \end{aligned}$$

$$\begin{aligned} F_y(Y_2) &= P(y \leq Y_2) = P(g(x) \leq Y_2) = P(x \leq x_2) \cup \{x'_2 \leq x \leq x''_2\} = \\ &= P(x \leq x_2) + P(x'_2 \leq x \leq x''_2) = F_x(x_2) + F_x(x''_2) - F_x(x'_2) \end{aligned}$$

$$Y_2 = g(x) \rightarrow x = x_2, x'_2, x''_2$$

- Def

• Beispiel mit $a, b \in \mathbb{R}$, $y = ax + b$ auf \mathbb{R} . $F_X(x)$ ist x
? $F_Y(y)$ ist y
- 11252

$$X = \frac{y-b}{a}$$

$a > 0$

$$F_Y(y) = P(y \leq Y) = P(ax + b \leq Y) = P\left(x \leq \frac{y-b}{a}\right) = F_X\left(\frac{y-b}{a}\right)$$

$a < 0$

$$F_Y(y) = P(X \geq \frac{y-b}{a}) = 1 - P(X \leq \frac{y-b}{a}) = 1 - F_X\left(\frac{y-b}{a}\right)$$

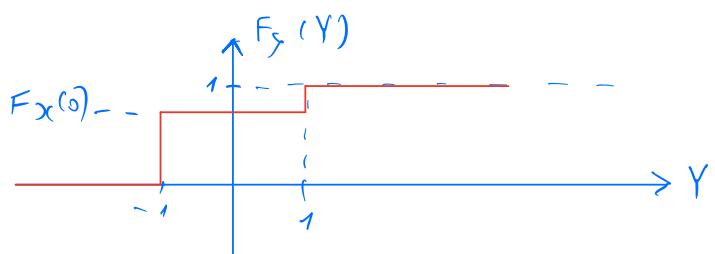
- Def

$$y = \begin{cases} -1, & x \leq 0 \\ 1, & x > 0 \end{cases} \quad . F_X(x), \text{ für } y \in \mathbb{R}$$

- 11252

$$P(Y = -1) = P(X \leq 0)$$

$$P(Y = 1) = P(X > 0) = 1 - P(X \leq 0)$$



- גיאומטריה

• מילוי מילוי מילוי, $y = ax + b$ נספ' $f_x(x)$ ב' x
 $? f_y(y)$ ב' y

ל' x_1, x_2, \dots, x_n נספ' y נספ' $y = g(x)$ ב' x כפונקציית $f_g(y) = \frac{f_x(x_1)}{|g'(x_1)|} + \dots + \frac{f_x(x_n)}{|g'(x_n)|}$

- פיזיקה

$$x = \frac{y - b}{a}, \quad g(x) = y = ax + b$$

$$f_y(y) = \frac{f_x(x_1)}{|g'(x_1)|} = \frac{f_x\left(\frac{y-b}{a}\right)}{|a|}$$

ין לו (Various) מילוי (Expected value) נסיעות. 2

continuous: $E\{x\} \triangleq \int_{-\infty}^{\infty} x \cdot f_x(x) dx$

discrete: $E\{x\} \triangleq \sum_{i=1}^n x_i \cdot P(x=x_i)$

? $E\{x\}$ יונ. $[x_1, x_2]$ ובור רינט גורן x

$$f_x(x) = \begin{cases} \frac{1}{x_2 - x_1}, & x_1 \leq x \leq x_2 \\ 0, & \text{Else} \end{cases}$$

$$\begin{aligned} E\{x\} &= \int_{-\infty}^{\infty} x \cdot f_x(x) dx = \frac{1}{x_2 - x_1} \cdot \int_{x_1}^{x_2} x \cdot dx = \\ &= \frac{1}{x_2 - x_1} \cdot \frac{(x_2^2 - x_1^2)}{2} \end{aligned}$$

$E\{x\} = \frac{1}{6} (1+2+3+4+5+6)$ לעומת $E\{x\}$ רגילה. $\Omega = \{1, \dots, 6\}$ נ"ז נסיעות

continuous: $E\{x|m\} \triangleq \int_{-\infty}^{\infty} x \cdot f_x(x|m) dx$ נסיעות נסיעות. 3

discrete: $E\{x|m\} \triangleq \sum_{i=1}^n x_i \cdot P(x=x_i|m)$

$$E\{g(x)\} = \int_{-\infty}^{\infty} g(x) \cdot f_x(x) dx$$

לינר סטטיסטיקות.

$$\begin{aligned}\sigma_x^2 &= \text{Var}(x) \triangleq E\left\{\underbrace{(x - E\{x\})^2}_{\text{פונקציית גורילה}}\right\} \\ &= E\{x^2 - 2xE\{x\} + E\{x\}^2\} = E\{x\}^2 - 2E\{x\} \cdot E\{x\} + E\{x\}^2\end{aligned}$$

הנחות.

- 10413

? נניח כי סדרת גורילה היא $[c_1, c]$ ותאך היא x
- 1052

$$E\{x\} = \frac{1}{2c} \cdot \int_{-c}^c x \cdot dx = 0$$

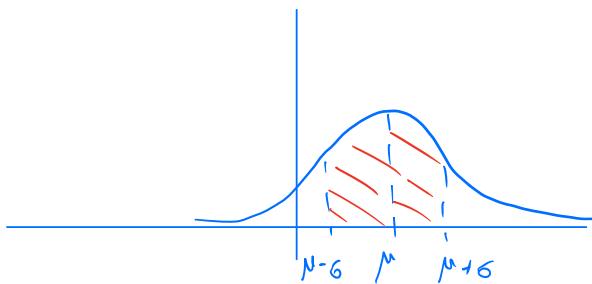
$$\text{Var}(x) = E\{x^2\} = \frac{1}{2c} \cdot \int_{-c}^c x^2 dx = \frac{1}{2c} \cdot \left(\frac{x^3}{3}\right)$$

- 10519

.5. לפירוט מתרגלים בקורס פיזיקה על ידי ש

$$f_x(x) = \frac{1}{\sqrt{2\pi \cdot \sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$E\{x\} = \mu, \quad \text{Var}(x) = \sigma^2$$



- 10.8.13

Defn → two types of joint distributions

$$P(X=0) = p$$

$$P(X=1) = q$$

- 10.8.13

$$E\{X\} = 0 \cdot p + 1 \cdot q = q$$

$$\text{Var}(X) = E[X^2] - E[X]^2 = 0^2 \cdot p + 1^2 \cdot q - q^2 = q - q^2 = q(1-q)$$

Independence

$$F_{x,y}(x, y) \stackrel{\Delta}{=} P(\{X \leq x\} \cap \{Y \leq y\}) = P(X \leq x, Y \leq y)$$

- 10.8.13

$$1. F_{x,y}(-\infty, y) = F_{x,y}(x, -\infty) = 0$$

$$2. F_{x,y}(-\infty, \infty) = 1$$

$$3. P(x_1 \leq X \leq x_2, y \leq Y) = F_{x,y}(x_2, y) - F_{x,y}(x_1, y)$$

$$4. P(x_1 \leq X \leq x_2, y_1 \leq Y \leq y_2) = F_{x,y}(x_2, y_2) - F_{x,y}(x_1, y_2) - F_{x,y}(x_2, y_1) + F_{x,y}(x_1, y_1)$$

$$f_{x,y}(x,y) \stackrel{\Delta}{=} \frac{\partial^2 F_{x,y}(u,v)}{\partial u \partial v} \Big|_{\begin{array}{l} u=x \\ v=y \end{array}} \quad \text{הנחות מינימום.}$$

$$F_{x,y} = \int_{-\infty}^x \int_{-\infty}^y f_{x,y}(u,v) du dv$$

$$P((x,y) \in D) = \iint_D f_{x,y}(u,v) du dv$$

ר' סידני סילברמן.

$$\text{לעדי } F_{x,y} \longrightarrow F_x, F_y = ?$$

$$F_x(x) = P(x \leq X, y \leq \infty) = F_{x,y}(x, \infty) = \int_{-\infty}^x \int_{-\infty}^{\infty} f_{x,y}(u,v) du dv$$

$$f_x(x) = \int_{-\infty}^{\infty} f_{x,y}(x,y) dy$$

$$f_y(y) = \int_{-\infty}^{\infty} f_{x,y}(x,y) dx$$

הנחות מינימום
לעדי סידני סילברמן!
ולעדי סידני סילברמן!

לעדי סידני סילברמן!
ולעדי סידני סילברמן!

$$F_{x,y} = F_x \cdot F_y$$

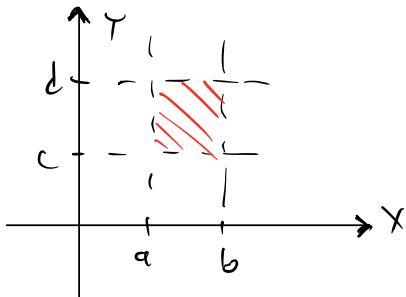
$$f_{x,y} = f_x \cdot f_y$$

רִנְגְּ גֶּפֶן מִבְּנֵי בָּבֶבֶן . 9

$$x \in [a, b]$$

$$y \in [c, d]$$

$$f_{x,y}(x,y) = \begin{cases} m(\text{const}) & , (x,y) \in \\ 0 & , \text{else} \end{cases}$$



$$\iint_{-\infty}^{\infty} m \, dx \, dy$$

$$m = \frac{1}{A} = \frac{1}{(b-a)(d-c)}$$

רִנְגְּ גֶּפֶן מִבְּנֵי בָּבֶבֶן . 10

$$f_{x,y}(x,y) = \frac{1}{2\pi \cdot |\sigma|^{0.5}} \cdot \exp \left\{ -\frac{1}{2} \left[(x - \mu_x, y - \mu_y) \cdot C^{-1} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix} \right] \right\}$$

$$|\sigma| = \sigma_x^2 + \sigma_y^2$$

$$\sigma_{x,y} = 0 : \text{נק}$$

$$f_{x,y}(x,y) = \frac{1}{2\pi \cdot \sigma_x \sigma_y} \cdot \exp \left\{ -\frac{1}{2} \frac{(x - \mu_x)^2}{\sigma_x^2} - \frac{1}{2} \frac{(y - \mu_y)^2}{\sigma_y^2} \right\} =$$

$$= \frac{1}{\sqrt{2\pi} \sigma_x} \cdot e^{-\frac{(x - \mu_x)^2}{2\sigma_x^2}} \cdot \frac{1}{\sqrt{2\pi} \sigma_y} \cdot e^{-\frac{(y - \mu_y)^2}{2\sigma_y^2}} = f_x(x) \cdot f_y(y)$$

ורא : סע

11. လုပ်လုပ်မှုများ

: အမြတ်

$x_i, i = 1, \dots, n$ ကို စွဲနေရန်
လုပ်လုပ်မှု

$$x_i = \begin{cases} 1, & \text{အမြတ် } A \text{ ဖြစ်သော } \\ 0, & \text{ခြင်း} \end{cases}$$

$$P(x_i=1) = P(A)$$

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i = P(A)$$

- အလုပ်လုပ်မှု

$$P(|x - p| \geq \varepsilon) \leq \varepsilon^2$$

$$E\{x_i\} = 1 \cdot P(A) + 0 \cdot P(\bar{A}) = P(A)$$

$$E\{\bar{x}_n\} = E\left\{\frac{1}{n} \sum_{i=1}^n x_i\right\} = \frac{1}{n} \sum_{i=1}^n E\{x_i\} = P(A)$$

$$\text{Var}_{x_i} = E\{x_i^2\} - E\{x_i\}^2 = 1 \cdot P(A) - P(A)^2 = P(A) \cdot (1 - P(A))$$

$$E\{(\bar{x}_n - P(A))^2\} = E\left\{\left(\frac{1}{n} \sum_{i=1}^n (x_i - P(A))^2\right)\right\}$$

$$\frac{1}{n^2} \cdot E\left\{\sum_{i=1}^n (x_i - P(A))^2 + \sum_{i \neq j} (x_i - P(A))(x_j - P(A))\right\} =$$

$$= \frac{1}{n^2} \sum_{i=1}^n E\{(x_i - P(A))^2\} = \frac{P(A)(1-P(A))}{n}$$

$P(A)(1-P(A))$

পৰিঃ প্র $P(|\bar{x}_n - P(A)| \geq \epsilon) \leq \epsilon^2 n \xrightarrow{n \rightarrow \infty} 0$. $\forall \epsilon > 0$

$$\lim_{n \rightarrow \infty} \bar{x}_n \xrightarrow{P} P(A)$$

: প্রমাণ . 2

$$E\{x_i\} = \mu \quad \text{for } i = 1, 2, \dots, n$$

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i = \mu$$

। এইটা সেজন্টের বাস্তবতা

সুনির্দিষ্ট হিসেব . 12

। বিনামূলক ক্ষেত্ৰে একটা অসম্ভব

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

$$f(\bar{x}_n) \xrightarrow{n} N(\mu, \frac{\sigma^2}{n})$$

$$f\left(\frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}}\right) \longrightarrow 0.1$$

ו' כ' ה' י' נ'

5 → 10'c

ט' כ' ב' נ' ק' ל' י'

א' מ' ג' א' מ' ג'
ל' נ' ס' ל' נ' ס' . 1
. 2

לעומת רג'סן מינימום.

המינימום של פונקציית האפסים הוא רג'סן.

Mean square Error

$$E \{ \text{MSE} \} = E \{ (\theta - \hat{\theta})^T (\theta - \hat{\theta}) \}$$

↓
 וריאנץ
 ↓
 וריאנץ

$$\hat{\theta}_{(\text{MSE})} = E \{ \theta | z \}$$

↓
 מינ. MSE

היפ:

הוכחה:

$$E \{ f(x) \cdot g(y) \} = E \{ E \{ f(x) \cdot g(y) | x \} \} = E \{ f(x) \cdot E \{ g(y) | x \} \}$$

↓ ... P(y|x) · P(x)
 וריאנץ

$$E \{ E \{ (\theta - \hat{\theta})^T (\theta - \hat{\theta}) | z \} \} \rightarrow \min_{\hat{\theta}} E \{ (\theta - \hat{\theta})^T (\theta - \hat{\theta}) | z \}$$

$$E \{ \theta^T \theta - 2\theta^T \hat{\theta} + \hat{\theta}^T \hat{\theta} | z \} =$$

$$E \{ \theta^T \theta | z \} - 2E \{ \theta^T \hat{\theta} | z \} + E \{ \hat{\theta}^T \hat{\theta} | z \} =$$

$$E \{ \theta^T \theta | z \} - 2\hat{\theta}^T \cdot E \{ \theta | z \} + \hat{\theta}^T \hat{\theta} =$$

$$E \{ \theta^T \theta | z \} + (\hat{\theta} - E \{ \theta | z \})^T (\cdot) - E \{ \theta | z \}$$

$$E\{\hat{\theta}_{MMSE}\} = E\{E\{\theta|z\}\} = E\{\theta\} \quad : \text{unbiased-achieved}$$

(Bayesian filtering) ~~filtering~~

$$E\{x|z\} = \int x \cdot P(x|z) dx$$

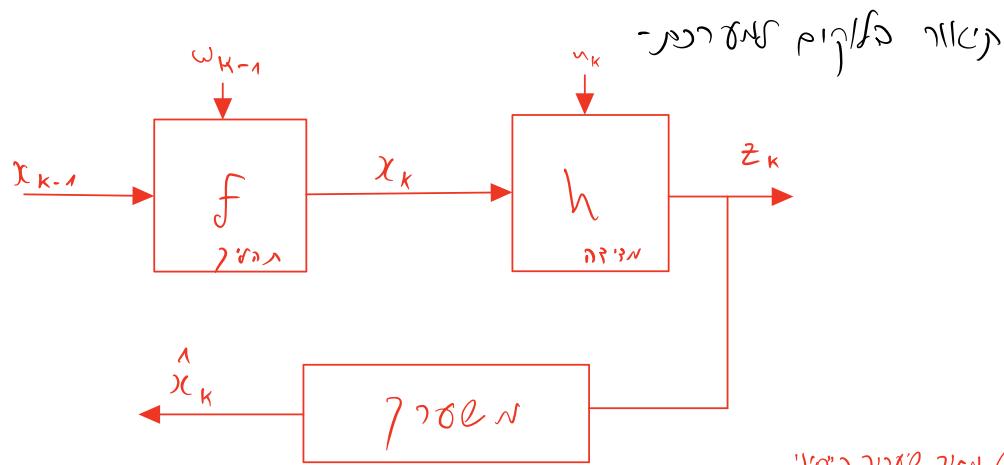
מיצג מושג

$$x_k \in \mathbb{R}^n \quad \text{הויה}$$

$$z_k \in \mathbb{R}^m \quad \text{הויה}$$

$$w_k \in \mathbb{R}^q \quad \text{הויה}$$

$$u_k \in \mathbb{R}^m \quad \text{הויה}$$



מmse: $\hat{x}_k = E\{x_k | z_1, \dots, z_k\} = \int x_k \cdot P(x_k | z_1, \dots, z_k)$

המיסים

$$P(x_0), z_{1:k} = \{z_1, \dots, z_k\}$$

$$P(x_k | z_{1:k}) \xrightarrow{\text{f}} P(x_{k+1} | z_{1:k+1})$$

f, h - process function
 next state - z_{k+1}

$$P(x_0) \xrightarrow{\quad} P(x_1 | z_1) \xrightarrow{\quad} P(x_k | z_{1:k})$$

- recursive function

Process Equation:

$$x_{k+1} = f(x_k, w_k) \quad f: \mathbb{R}^n \times \mathbb{R}^v$$

Measurement Equation:

$$z_{k+1} = h(x_{k+1}, u_{k+1}) \quad h: \mathbb{R}^n \times \mathbb{R}^m$$

Filtering (State estimation):

$$\hat{x}_k = \text{min}_{\hat{x}_k} \text{ or } \text{prior belief} \quad \hat{x}_k = (x_k | z_{1:k}) \text{ : MMSE } P_{k|k} \text{ : Covariance}$$

- יסוד למדעי המחשב || כטב

Bayesian Recursion:

$$P(x_k | z_{1:k}) \rightarrow P(x_{k+1} | z_{1:k+1})$$

Time Propagation: העדר מיפוי - מיפוי עליון

$$P(x_{k+1} | z_{1:k}) = \int_{-\infty}^{\infty} P(x_{k+1} | x_k, z_{1:k}) P(x_k | z_{1:k}) dx_k$$

Measurement Update: העדר פיזור

$$P(x_{k+1} | z_{1:k+1}) = \frac{P(z_{k+1} | x_{k+1}, z_{1:k}) \cdot P(x_{k+1} | z_{1:k})}{\int P(z_{k+1} | x_{k+1}, z_{1:k}) \cdot P(x_{k+1} | z_{1:k}) dx_{k+1}}$$

$$P(x_k | z_{1:k}) \xrightarrow{f} P(x_{k+1} | z_{1:k}) \xrightarrow{z_{k+1}, h} P(x_{k+1} | z_{1:k+1})$$

העדר מיפוי - מיפוי עליון העדר מיפוי - מיפוי עליון העדר מיפוי - מיפוי עליון

$$P(x_{k+1} | x_k, z_{1:k}) = (\text{Transmission P of }) \text{ Clean } \text{ or } \text{ Dirty}$$

$$x_{k+1} = f(x_k, w_k)$$

העדר מיפוי - מיפוי עליון
העדר מיפוי - מיפוי עליון

$$P(x_{k+1} | x_k, z_{1:k}) = P(x_{k+1} | x_k)$$

$$P(x_{k+1} | x_k) = \frac{P_{w_k}(x_{k+1} - f(x_k, o))}{|f'(x_k, o)|}$$

$P(z_k | x_k, z_{1:k-1})$ - Likelihood Pdf מודל

$$z_k = h(x_k, u_k)$$

תפקידו כ

$$P(z_k | x_k, z_{1:k-1}) = P(z_k | x_k)$$

($z_{1:k-1}$ -> ידית z_k : x קבוע / קבוע)

- מודולו נזילות : ערך

$$\begin{cases} x_{k+1} = f(x_k) + \omega_k \\ z_{k+1} = h(x_{k+1}) + u_k \end{cases} \quad \begin{array}{l} P_{\omega_k}, P_{u_k} \\ \text{במקרה של } z_{k+1} \end{array}$$

$$P(x_{k+1} | x_k) = P_{\omega_k} (x_{k+1} - f(x_k))$$

$$P(z_{k+1} | x_{k+1}) = P_{u_{k+1}} (z_{k+1} - h(x_{k+1}))$$

$$P(x_k | z_{1:k}) = ?$$

המודולו הקיים מתקיים במדויק.

• נזכיר ש'ילובים

$$x_{k+1} = F_k \cdot x_k + \omega_k, \quad \omega_k \sim N(\omega_k | 0, Q_k)$$

$$z_{k+1} = H_{k+1} \cdot x_{k+1} + u_{k+1}, \quad u_k \sim N(u_k | 0, R_k)$$

$P(x_k | z_{1:k})$ = Kalman Filter (k.f) גזירה מינימלית גזירה

(K.F - Kalman Filter) NSP No. 3

$$N(x|\mu, Q) = \frac{1}{(2\pi|Q|)^{n/2}} \exp \left\{ -\frac{1}{2}(x-\mu)^T Q^{-1} (x-\mu) \right\}$$

$$P(x_0) = N(x_0 | x_{0/0}, P_{0/0})$$

$$\hat{x}_{k|T} \triangleq E\{x_k | z_{1:T}\}$$

$$\hat{x}_{0/0} = E\{x_0\}$$

$$P_{k|T} \triangleq E\{(x_k - \hat{x}_{k|T})(x_k - \hat{x}_{k|T})^T | z_{1:T}\}$$

$$\omega_k, v_k = (H \text{proj} \omega_0) x_0 \rightarrow \text{proj}$$

- NSP 13.9 附录 13.2

$$P(x_k | z_{1:k}) = N(x_k | \hat{x}_{k|k}, P_{k|k})$$

$$\hat{x}_{k|k} \rightarrow \hat{x}_{k+1|k} = E\{x_{k+1} | z_{1:k}\}$$

$$P(x_{k+1} | z_{1:k}) = N(x_{k+1} | \hat{x}_{k+1|k}, P_{k+1|k})$$

$$\hat{x}_{k+1} = E\{x_{k+1} | z_{1:k}\} = E\{F_k x_k + \omega_k | z_{1:k}\} = F_k \underbrace{E\{x_k | z_{1:k}\}}_{\hat{x}_{k|k}}$$

$$\hat{x}_{k+1|k} = F_k \hat{x}_{k|k}$$

$$\begin{aligned}
P_{k+1|k} &= E \left\{ \left(\underbrace{x_{k+1} - \hat{x}_{k+1|k}}_{F_k x_k + w_k} \right) (\cdot)^T \mid z_{1:k} \right\} \\
&\quad \underbrace{\hat{x}_{k+1|k}}_{F_k \hat{x}_{k|k} + w_k} \\
&= E \left\{ (F_k \hat{x}_{k|k} + w_k) (\cdot)^T \mid z_{1:k} \right\} \\
&= E \left\{ F_k \tilde{x}_k \tilde{x}_k^T F_k^T + w_k \tilde{x}_k F_k^T + F_k \tilde{x}_k w_k^T + w_k w_k^T \mid z_{1:k} \right\} \\
&= F_k \cdot P_{k|k} F_k^T + Q_k
\end{aligned}$$

$$P_{k+1|k} = F_k P_k F_k^T + Q_k$$

- נציג יסודות נייר . נ

$$\begin{aligned}
P(x_{k+1} \mid z_{1:k}, z_{k+1}) &= \frac{P(z_{k+1} \mid x_{k+1}) P(x_{k+1} \mid z_{1:k})}{P(z_{k+1} \mid z_{1:k})}
\end{aligned}$$

$$P(x \mid y) = \frac{P(y \mid x)}{P(y)}$$

. 条件分布的联合概率

$$\mu_x = E\{x\}$$

$$\mu_y = E\{y\}$$

$$\text{协方差矩阵} \Sigma = \begin{bmatrix} P_x & P_{xy} \\ P_{yx} & P_y \end{bmatrix}$$

'SIC

$$P(x|y) = N(x | E\{x|y\})$$

$$E\{x|y\} = \mu_x - P_{xy} \cdot P_y^{-1}$$

$$P_{xy} = P_x - P_{xy} \quad \underline{\text{或}}$$

$$P(x,y) = \frac{1}{(2\pi|\Sigma|)^{(m+n)/2}} \cdot \exp\left\{-\frac{1}{2} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}^\top \Sigma^{-1} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}\right\}$$

$$P(y) = \frac{1}{(2\pi|P_y|)^{m/2}} \cdot \exp\left\{-\frac{1}{2} (y - \mu_y)^\top P_y^{-1} (\cdot)\right\}$$

$$\star \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}^\top \Sigma^{-1} [\cdot] - (y - \mu_y)^\top P_y^{-1} (\cdot)$$

$$C^{-1} = \begin{bmatrix} P_x & P_{xy} \\ P_{yx} & P_y \end{bmatrix}^{-1} = \begin{bmatrix} A & B \\ B^T & D \end{bmatrix}$$

�の式

$$\left\{ \begin{array}{l} A = (P_x - P_{xy} P_y^{-1} P_{yx})^{-1}, \quad B = -A P_{xy} P_y^{-1} \\ D = P_y^{-1} + P_y^{-1} P_{yx} A P_{xy} P_y^{-1} \end{array} \right.$$

⊗

$$\begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}^T \begin{bmatrix} A & B \\ B^T & D - P_y^{-1} \end{bmatrix} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix} =$$

$$(x - \mu_x)^T A (x - \mu_x) + \lambda (x - \mu_x)^T B (y - \mu_y) +$$

$$+ (y - \mu_y)^T (D - P_y^{-1}) (y - \mu_y) =$$

$$= [x - (\underbrace{\mu_x + P_{xy} P_y^{-1} (y - \mu_y)}_{E\{x|y\}})]^T A [\cdot]$$

$P_{xy} = A^{-1}$

$$P(x|y) = \frac{P(x,y)}{P(y)} = \frac{1}{\left(\frac{(2\pi |c|)^{w+n/2}}{(2\pi |P_y|)^{w/2}} \right)} \cdot \exp\{ \cdot \}$$

$$|P_{x|y}| \stackrel{?}{=} \frac{|c|}{|P_y|} \quad (2\pi |P_{x|y}|)^{n/2}$$

$$C = \begin{bmatrix} P_{xx} & P_{xy} \\ P_{yx} & P_y \end{bmatrix} =$$

$$\begin{bmatrix} L & P_{xy} \\ 0 & P_y \end{bmatrix} \cdot \begin{bmatrix} I_n & 0 \\ P_y^{-1} & I_m \end{bmatrix} \quad \begin{aligned} L + P_{xy} \cdot N &= P_x \\ P_y N &= P_{yx} \rightarrow N = P_y^{-1} P_{yx} \\ L &= P_x - P_{xy} P_y^{-1} P_{yx} = P_x I_m \end{aligned}$$

$$|C| = |L| \cdot |P_y| \rightarrow |P_{x|y}|$$

$$\begin{aligned} \hat{x}_{n+1|n+1} &= E \{ (x_{k+1} | z_{1:k}) | z_{n+1} \} \\ &= E \{ \underbrace{x_{k+1}}_{\hat{x}_{k+1|k}} | z_{1:k} \} + \underbrace{P_{x_{k+1}, z_{k+1}|z_{1:k}} P_{z_{n+1}|z_{1:k}}^{-1}}_{H_{n+1} - k_{n+1}} \end{aligned}$$

$$\begin{aligned} &(z_{k+1} - \underbrace{E \{ z_{k+1} | z_{1:k} \}}_{E \{ H_{n+1} x_{n+1} + u_{k+1} | z_{1:k} \}}) \\ &= H_{n+1} \underbrace{E \{ x_{k+1} | z_{1:k} \}}_{\hat{x}_{k+1|k}} \end{aligned}$$

$$P_{z_{n+1}|z_{1:k}} = E \{ (\underbrace{z_{n+1} - H_{n+1} \hat{x}_{n+1|k}}_{H_{n+1} \tilde{x}_{k+1|k} + u_{n+1}})(\cdot)^T | z_{1:k} \}$$

$$= H_{n+1} P_{k+1|k} H_{k+1}^T + R_{k+1}$$

$$\begin{aligned} P_{x_{n+1}, z_{n+1}|z_{1:k}} &= E \{ (x_{k+1} - \hat{x}_{k+1|k})(z_{n+1} - H_{n+1} \hat{x}_{n+1|k})^T \} \\ &= E \{ \tilde{x}_{k+1|k} (u_{n+1}^T + \tilde{x}_{k+1|k}^T H_{n+1}^T) \} = P_{k+1|k} H_{n+1}^T \end{aligned}$$

$$P_{k+1/k+1} = P_{k+1/k} - P_{k+1/k} H_{k+1}^T \times (H_{k+1} P_{k+1/k} H_{k+1}^T + R_{k+1})^{-1} H_k P_{k+1/k}$$

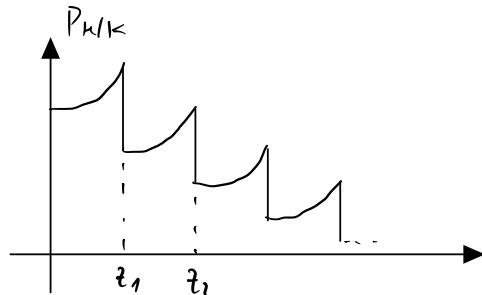
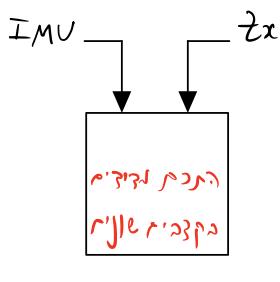
הונר ~ חישוב

$$K_{k+1} = P_{k+1/k} H_{k+1}^T (H_{k+1} P_{k+1/k} H_{k+1}^T + R_{k+1})^{-1}$$

השאלה מושג

$$\hat{x}_{k+1/k+1} = \hat{x}_{k+1/k} + K_{k+1} (\hat{z}_{k+1} - H_{k+1} \hat{x}_{k+1})$$

$$P_{k+1/k+1} = (I - K_{k+1} H_{k+1}) P_{k+1/k}$$



۱۲۱ | ۶۱، ۵۹

۶ ۷۱

: لکلکیں ۱۰۰۱

۱	پونہ	پونہ
۲	پونہ	پونہ
۳	پونہ	پونہ
۴	پونہ	پونہ
۵	پونہ	پونہ

Propagation

$$\begin{cases} \hat{x}_{k+1|k} = A_k \hat{x}_{k|k} + B_k u_k & (\text{KF}) \text{ forward } \\ P_{k+1|k} = A_k P_{k|k} A_k^T + Q_k \end{cases}$$

Update

$$\begin{cases} K_{k+1} = P_{k+1|k} H_{k+1}^T (H_{k+1} P_{k+1|k} H_{k+1}^T + R_{k+1})^{-1} \\ \hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + K_{k+1} (z_{k+1} - H_{k+1} \hat{x}_{k+1|k}) \\ P_{k+1|k+1} = (I - K_{k+1} H_{k+1}^T) P_{k+1|k} = \\ = \underbrace{(I - K_{k+1} H_{k+1}^T)}_{\rightarrow} P_{k+1|k} + K_{k+1} R_{k+1} K_{k+1}^T \end{cases}$$

(EKF)

$$\begin{aligned} x_{k+1} &= f(x_k, \omega_k) \\ z_{k+1} &= h(x_{k+1}, u_{k+1}) \end{aligned}$$

הנחתה היא ש-KF מחליף מטרית המרחב (במיון גיאומטריה) על ידי מטרית מילויים (במיון מילויים)

$$(\hat{x}_{k|k}, \hat{x}_{k+1|k} - P_{k|k})$$

ר' פ' מ' ג' כ' י' ס' נ' -

$$\text{ג'ג' } \tilde{x}_{k|k} \triangleq x_k - \hat{x}_{k|k}$$

$$\|\tilde{x}_{k|k}\| \ll 1$$

$$E\{\hat{x}_{n|n} | z_{1:k}\} = E\{x_k | z_{1:k}\} - \hat{x}_{k|k} = 0$$

$$A_k = \frac{\partial f}{\partial x_k} \Big|_{x_k = \hat{x}_{k|k}, w_k=0}$$

$$C_k = \frac{\partial f}{\partial w_k} \Big|_{w_k=0, x_k = \hat{x}_{k|k}}$$

$$H_k = \frac{\partial h}{\partial x_k} \Big|_{x_k = \hat{x}_{k|k}, u_k=0}$$

$$D_k = \frac{\partial h}{\partial u_k} \Big|_{u_k=0, x_k = \hat{x}_{k|k}}$$

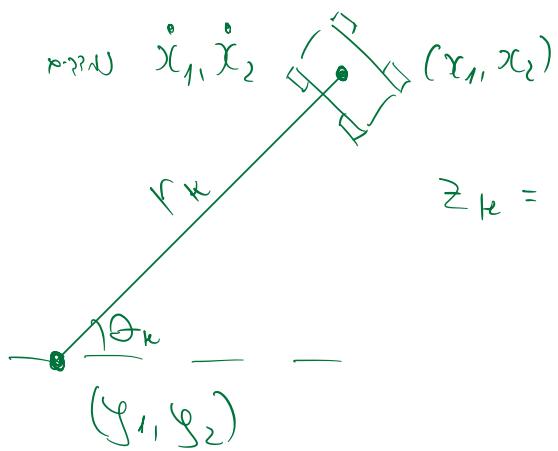
ר' פ' מ' ג' $\hat{x}_{n+1|k} = f(\hat{x}_{k|k}, 0)$

ו' פ' מ' ג' $P_{k+1|k} = A_k P_{k|k} A_k^T + C_k Q_k C_k^T$

ר' פ' מ' ג' $K_{k+1} = P_{k+1|k} H_{k+1}^T (H_{k+1} P_{k+1|k} H_{k+1}^T + D_{k+1} R_{k+1} D_{k+1}^T)^{-1}$

ר' פ' מ' ג' $\hat{x}_{n+1|k+1} = \hat{x}_{n+1|k} + K_{k+1}(z_{k+1} - h(\hat{x}_{n+1|k}, 0))$

ו' פ' מ' ג' $P_{k+1|k+1} = (I - K_{k+1} H_{k+1}) P_{k+1|k} (\cdot)^T +$
 $+ K_{k+1} D_{k+1} P_{k+1} D_{k+1}^T K_{k+1}^T$



運動方程 $\ddot{x}_1, \ddot{x}_2 \sim \omega_N - f_{\text{ext}}$

$$\begin{bmatrix} \ddot{x}_1 \\ \ddot{x}_2 \end{bmatrix} = \begin{bmatrix} P_k^T \\ 0_n \end{bmatrix} = \begin{bmatrix} (x_1 - g_1)^2 + (x_2 - g_2)^2 \\ \frac{g^{-1}(x_1 - g_1)}{x_1 - g_1} \end{bmatrix} + \begin{bmatrix} u_{r_k} \\ u_{\theta_k} \end{bmatrix}$$

$h(x_1, x_2)$

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_{k+1} = \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_{A_k} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_k + \underbrace{\begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix}}_{u_k} \Delta t + \begin{bmatrix} \omega_1 \\ \omega_2 \end{bmatrix}_k$$

$$\begin{bmatrix} x_1 \\ x_2 \\ \dot{x}_1 \\ \dot{x}_2 \end{bmatrix}_{k+1} = \begin{bmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \dot{x}_1 \\ \dot{x}_2 \end{bmatrix}_k + \begin{bmatrix} 0 \\ 0 \\ q_1 \\ q_2 \end{bmatrix}_k \Delta t + \begin{bmatrix} \omega_1 \\ \omega_2 \end{bmatrix}_k$$

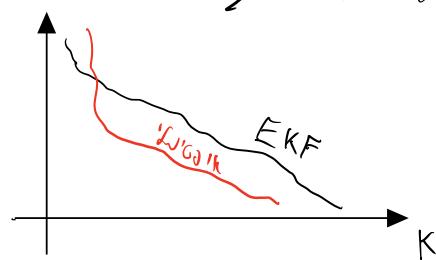
$$e^{A \Delta t} = I + A \cdot \Delta t$$

$$\text{הypothesis} \quad \hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + K_{k+1}(z_{k+1} - h(\cdot))$$

EKF / σ^2

$$P_{k+1|k} \leq E\{(x_k - \hat{x}_{k+1|k})(\cdot)^T\}$$

$$P_{k+1|k} \geq E\{(x_k - \hat{x}_{k+1|k})(\cdot)^T\}$$



$$P_{k+1|k} = A_k P_{k|k} A_k^T + C_k Q_k C_k^T + \underline{\epsilon}_k$$

EKF / σ^2 $P_{k+1|k}$ ρ^2

$$\hat{x}_{k|k-1} = H_k \cdot \hat{x}_{k|k-1}$$

$$\tilde{x}_{k|k-1} = \tilde{x}_k - \hat{x}_{k|k-1} = H_k x_k + u_k - H_k \hat{x}_{k|k-1} = H_k \hat{x}_{k|k-1} + u_k$$

$$\text{cov}(\tilde{x}_{k|k-1}) = E\{(H_k \tilde{x}_{k|k-1} + u_k)(\cdot)^T\} =$$

$$= \underbrace{H_k P_{k|k-1} H_k^T}_{\text{MP}} + R_k = V_k$$

$$\|\tilde{z}_{n|n-1}\|_2 \geq 3\lambda_{\max}(\tilde{\Sigma}_n) \quad - \text{Proof by contradiction}$$

- $z_{1:n-1}$ is 'for given past z_n good representation'

$$P(z_n | z_{1:n-1}) = \int P(z_n | x_n) P(x_n | z_{1:n-1}) dx_n$$

$$\text{evidence} = E\{P(z_n | x_n) | z_{1:n-1}\}$$

$$P(z_n | x_n) = P(z_n | \tilde{x}_{n|n-1}) + \frac{\partial P}{\partial x_n} \Big|_{x_n = \tilde{x}_{n|n-1}} \cdot \tilde{x}_{n|n-1} + O(\tilde{x}_{n|n-1}^2)$$

$$\begin{aligned} P(z_n | z_{1:n-1}) &\approx P(z_n | \tilde{x}_{n|n-1}) + \epsilon \\ &= N(z_n - h(\tilde{x}_{n|n-1}) / \sigma, R_n) \\ &\propto \exp \left\{ -\frac{1}{2} (z_n - \underbrace{h(\tilde{x}_{n|n-1})}_{\hat{z}_{n|n-1}})^T R_n^{-1} (\cdot) \right\} \end{aligned}$$

$$\|\tilde{z}_{n|n-1}\|_2^2 = \tilde{z}_{n|n-1}^T \tilde{z}_{n|n-1} = (z_n - h(\tilde{x}_{n|n-1}))^T$$

($[k, k+T]$ has form of σ) 173217 10'5

$\eta_k > \varepsilon$ if σ is not 0

$$P(\eta_k > \varepsilon | [k, k+T]) \leq \frac{n_k}{T}$$

$$\frac{1}{T} \cdot \sum_{m=1}^T \eta_{m+k} > \varepsilon$$

- now prove

$$\overset{\text{def}}{\underset{\text{def}}{x_{n|k}^{(i)}}} = EKF \left(\overset{\text{def}}{\underset{\text{def}}{x_{0|0}^{(i)}}} \right), \quad i = 1, \dots, N$$

$$\text{then } \bar{w}_k^{(i)} = \exp \left\{ -\frac{1}{2} \eta_k^{(i)} \right\}, \quad i = 1, \dots, N$$

$$\text{prob. } w_k^{(j)} = \frac{\bar{w}_k^{(j)}}{\sum_{i=1}^N \bar{w}_k^{(i)}}, \quad j = 1, \dots, N$$

$$j^* = \arg \max_j w_k^{(j)}$$

$$\overset{\text{def}}{\underset{\text{def}}{x_{n|k}^*}} = \overset{\text{def}}{\underset{\text{def}}{x_{n|k}^{(j*)}}}$$

$$\text{prob. } \overset{\text{def}}{\underset{\text{def}}{x_{n|k}}} = \sum_j w_k^{(j)} \overset{\text{def}}{\underset{\text{def}}{x_{n|k}^{(j)}}}$$

$$z_{k+1} = \underbrace{H_{k+1}x_k + u_{k+1}}_{\text{measured}} + v_{k+1}$$

$$\begin{cases} x_{k+1} = A_k x_k + w_k \\ z_{k+1} = H_{k+1}x_{k+1} + u_{k+1} \end{cases}$$

z_{k+1} for given A_k, x_k process

$$y_k \triangleq \begin{bmatrix} x_k \\ \text{col}(A_k) \end{bmatrix}$$

$$\text{col}(A_k) = \begin{bmatrix} q_1 \\ \vdots \\ q_n \end{bmatrix} \quad A_k = \begin{bmatrix} q_1^T \\ \vdots \\ q_n^T \end{bmatrix}$$

$$z_{k+1} \quad \text{from } y_k \quad \text{process}$$

$$y_{k+1} = \begin{bmatrix} f(y_k) \\ A_k x_k \\ \text{col}(A_k) \end{bmatrix} + \begin{bmatrix} w_k \\ 0 \end{bmatrix}$$

$$f(y_k) = \begin{bmatrix} f_1(y_k) \\ f_2(y_k) \end{bmatrix}, \quad z_{k+1} = \underbrace{\begin{bmatrix} H_{k+1} & D_{m+n^2} \end{bmatrix}}_{H_{k+1}} y_{k+1} + u_{k+1}$$

- EKF (e")

$$F_k = \frac{\partial f}{\partial x_k} = \begin{bmatrix} \frac{\partial f_1}{\partial x_k} & \frac{\partial f_1}{\partial \text{col}(A_k)} \\ \frac{\partial f_2}{\partial x_k} & \frac{\partial f_2}{\partial \text{col}(A_k)} \end{bmatrix}$$

$$F_k = \begin{bmatrix} A_k & \overset{D_k \text{ of}}{\underset{\partial \text{col}(A_k)}{\underset{\partial}{\underset{\text{col}(A_k)}}{\left| \begin{array}{c} \frac{\partial A_k}{\partial x_k} \\ \frac{\partial \text{col}(A_k)}{\partial x_k} \end{array} \right|}}} \\ \mathbb{I}_{n^2 \times n} & I_{n^2 \times h^2} \end{bmatrix}$$

$$\underbrace{D_k}_{\mathbb{I}_{n \times n} \otimes x_k^T} \quad \underbrace{\text{col}(A_k)}$$

$$A_k x_k = \begin{bmatrix} q_1^T \\ \vdots \\ q_n^T \end{bmatrix} x_k = \begin{bmatrix} q_1^T x_k \\ \vdots \\ q_n^T x_k \end{bmatrix} = \begin{bmatrix} x_k^T \\ \mathbb{I}_{1 \times n} \cdots \mathbb{O} \\ x_k^T \cdots \\ \vdots \\ x_k^T \end{bmatrix} \begin{bmatrix} q_1 \\ \vdots \\ q_n \end{bmatrix}$$

$n \times h^2$

11/12/17 .5

$$P(x_k | A_k, z_{1:k})$$

$$q = \begin{bmatrix} e \cdot \sin\left(\frac{\theta}{2}\right) \\ \cos\left(\frac{\theta}{2}\right) \end{bmatrix} \quad \|q\|_2 = 1$$

$$A^T A = I_{3 \times 3}$$

$$A(q_1 * q_2) = A(q_1) A(q_2)$$

$$A^T = A(q^{-1})$$

$$\dot{q} = A(\bar{\omega})q = \underbrace{\begin{bmatrix} 0 & -\omega_3 & \omega_2 & 0 \\ \omega_3 & 0 & -\omega_1 & 0 \\ -\omega_2 & \omega_1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{A^T = -A} q$$

$$q_{k+1} = \exp\{A(\bar{\omega}) \cdot \Delta t\} q_k$$

$$r_{k+1} = \underbrace{A(q_{k+1})}_{I_{3 \times 3} - 2q_r [\hat{e} \times]} \bar{r}_m + u_{k+1} + 2[\hat{e} \times]^2$$

$$q_k = \begin{bmatrix} \hat{e} \\ q_r \end{bmatrix}, \quad [\hat{e} \times] \triangleq \begin{bmatrix} 0 & -q_3 & q_2 \\ q_3 & 0 & -q_1 \\ -q_2 & q_1 & 0 \end{bmatrix}$$

985'')

6 218'c

: 7182.7 1021.1

EKF ~125n .1
UKF .2

28 Nov 1967 15125A

$$x_{k+1} = f(x_k) + \omega_k$$

$$z_{k+1} = h(x_{k+1}) + u_{k+1}$$

•insi վարժութեայի ընթացքը - EKF միջավայրը

unscented KF (UKF) 2

- מושג של אגדת מס' 31 ו- מושג של אגדת מס' 30.

$$P(x_k | z_{1:n}) \xrightarrow{f} P(x_{k+1} | z_{1:k}) \xrightarrow{z_{n+1}} P(x_{k+1} | z_{1:n+1})$$

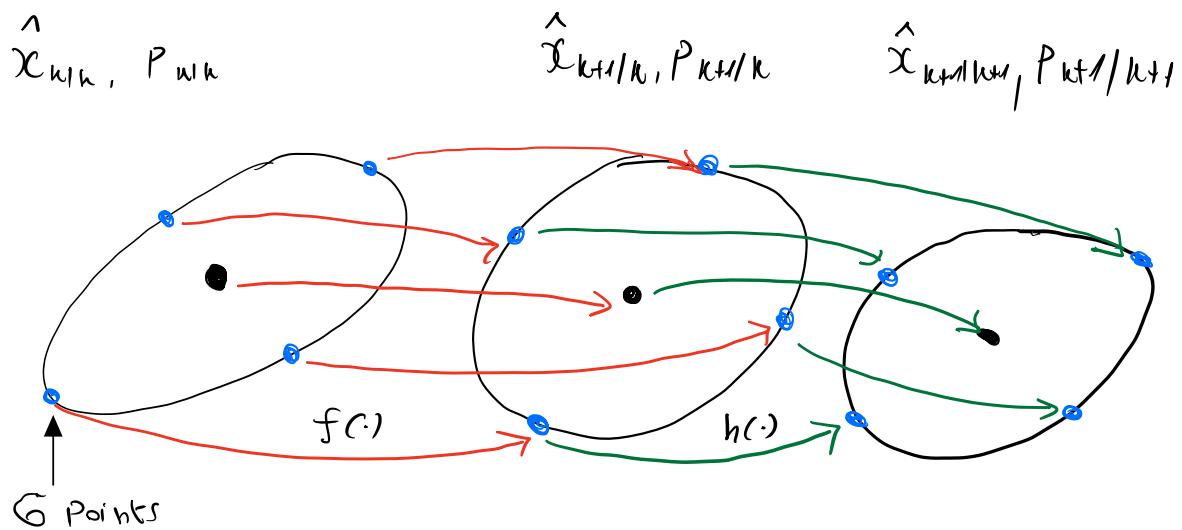
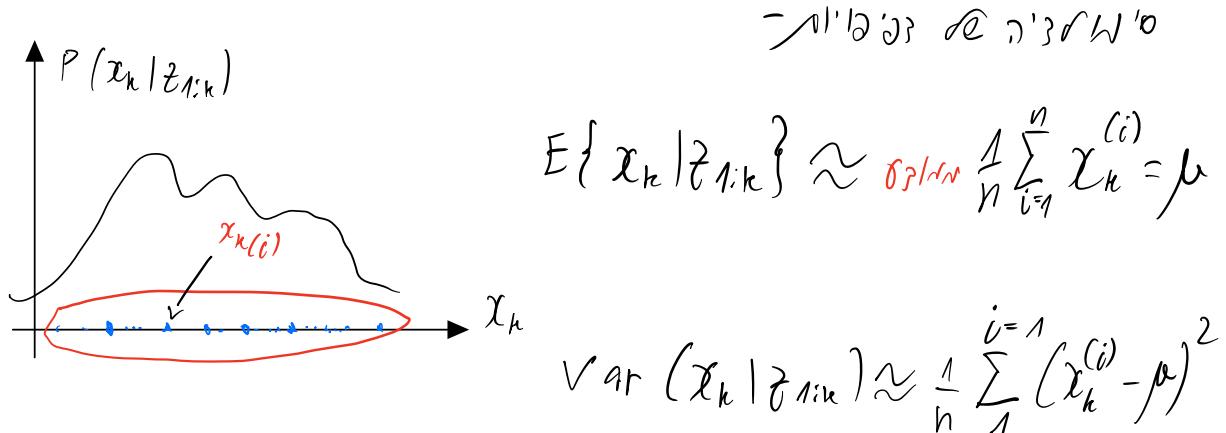
$$\hat{\chi}_{k|k}, P_{k|k} \xrightarrow{f} \hat{\chi}_{k+1|k}, P_{k+1|k} \xrightarrow{\hat{f}_{k+1}} \hat{\chi}_{k+1|k+1}, P_{k+1|k+1}$$

$$\begin{aligned}
 P_{k|k} &= E\{(x_k - \hat{x}_{k|k})(\cdot)^T | z_{1:k}\} \geq 0 = A \cdot A^T = \\
 &= [A_1 | A_2 | \cdots | A_n] \begin{bmatrix} A_1^T \\ \vdots \\ A_n^T \end{bmatrix} = \sum_{i=1}^n A_i \cdot A_i^T = \frac{1}{n} \sum_{i=1}^n (\sqrt{n} A_i) (\sqrt{n} A_i)^T
 \end{aligned}$$

$$\xi_i \triangleq \hat{x}_{n|n} + \sqrt{n} A_i = \frac{1}{n} \sum_{i=1}^n (\xi_i - \hat{x}_{n|n})(\cdot)^\top$$

$$x_n \sim P(x_n | z_{1:n})$$

מבחן גיבוב נורמל



UKF

1. Generate S points: $\hat{x}_{k|k}, P_{k|k} \in \mathbb{R}^{L \times L} -$

$$s_0 = \hat{x}_{k|k}$$

$$s_i = s_0 + \sqrt{L} A_i, \quad i=1, \dots, L \quad (P_{k|k} = A A^T)$$

$$s_{i+L} = s_0 - \sqrt{L} A_i, \quad w_i = w_{i+L} = \frac{1}{2L}$$

2. True Prop -

$$x_i = f(s_i), \quad i=0, \dots, 2L$$

$$\hat{x}_{k+1|k} = \sum_{i=0}^{2L} w_i x_i$$

$$P_{k+1|k} = \sum_{i=0}^{2L} w_i (x_i - \hat{x}_{k+1|k})(\cdot)^T + Q_k$$

3. Regenerate S points -

$$P_{k+1|k} = A \cdot A^T \rightarrow s_i, \quad i=0, \dots, 2L$$

4. Meas update -

$$\text{מבחן} \quad z_i = h(s_i), \quad i=0, \dots, 2L$$

$$\hat{z} = \sum_{i=0}^{2L} w_i z_i$$

$$\hat{\Sigma}_k = \sum_{i=0}^{2L} \omega_i (\vec{z}_i - \hat{\vec{z}}) (\vec{z}_i - \hat{\vec{z}})^T + R_k$$

$$C_{\hat{z}\hat{z}} = \sum_{i=0}^{2L} \omega_i (\vec{z}_i - \hat{x}_{k+1/k}) (\vec{z}_i - \hat{\vec{z}})^T$$

由此可知 $K_{kk} = C_{\hat{z}\hat{z}} (\hat{\Sigma}_k)^{-1}$

$$\hat{x}_{k+1/k+1} = \hat{x}_{k+1/k} + K_{k+1} (\vec{z}_{k+1} - \hat{\vec{z}})$$

$$P_{k+1/k+1} = P_{k+1/k} - \underbrace{K_{k+1} (\hat{\Sigma}_k)^{-1} K_{k+1}^T}_{C_{\hat{z}\hat{z}} (\hat{\Sigma}_k)^{-1} C_{\hat{z}\hat{z}}^T}$$

$$\text{cov}(x|y) = \underbrace{\text{cov}(x)}_{\vec{z}_{k+1}} - \underbrace{\text{cov}(x,y)}_{\text{cov}(x,y)} \cdot \underbrace{\text{cov}(y)^{-1} C^*)^T}_{P_{k+1/k}}$$

✓ 1/15/19

7/18/19

: 21021 10211

- Bayesian Filtering .1
- SLLN .2
- Importance Sampling .3
- Particle Filtering .4

1. Bayesian Filtering

$$a. P(x_{n+1} | z_{0:n}) = \int P(x_{n+1} | x_n) P(x_n | z_{0:n}) dx_n$$

$$b. P(x_{n+1} | z_{0:n+1}) \propto P(z_{n+1} | x_{n+1}) P(x_{n+1} | z_{0:n})$$

2. SLLN

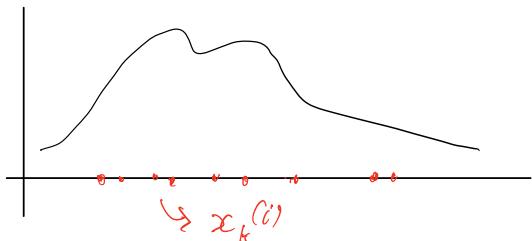
. $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n f(x^{(i)}) = E\{f(x)\}$

$\underbrace{x^{(i)}}_{\text{sample}} \sim P(x)$: $P(x)$ \rightarrow x \sim δ_x
 $x^{(i)}$ \sim $P(x_k | z_{0:n})$

$$\hat{P}(x_k | z_{0:n}) = \frac{1}{n} \sum_{i=1}^n \delta(x_k - x_k^{(i)})$$

$$x_k^{(i)} \sim P(x_k | z_{0:n})$$

$$\begin{aligned} \hat{P}(x_k | z_{0:n}) &\xrightarrow{n \rightarrow \infty} E\{\delta(x_k - x_k)\} = \\ &= \int \delta(x_k - x_k) P(x_k | z_{0:n}) dx_k = P(x_k | z_{0:n}) \end{aligned}$$

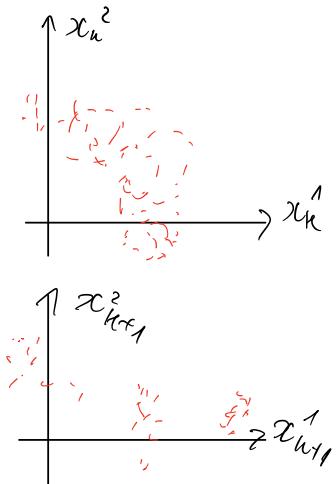


$$\hat{P}(x_k | z_{0:k}) = \frac{1}{n} \sum_{i=1}^n d_{k,i} (x_k - x_n^{(i)})$$

$$\sum_{i=1}^n f(x_n^{(i)}) \hat{P}(x_n^{(i)} | z_{0:k}) \xrightarrow{n \rightarrow \infty} E\{x_k | z_{0:k}\}$$

$\begin{cases} 1/n, & x_n^{(i)} \neq \bar{x}_n \\ 0, & x_n^{(i)} = \bar{x}_n \end{cases}$

$$\hat{P}(x_k | z_{0:k})$$

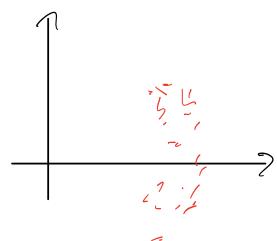


$$x_k^{(i)} = \begin{bmatrix} x_k^{(i)1} \\ x_k^{(i)2} \end{bmatrix}$$

$$\xrightarrow{\quad} \hat{P}(x_{k+1} | x_k)$$

$$x_{k+1} = f(x_k, w_k)$$

$$\hat{P}(x_{k+1} | z_{0:k})$$



$$\xrightarrow{\quad} \hat{P}(z_{k+1} | x_{k+1})$$

$$z_{k+1} = h(x_{k+1}, u_{k+1})$$

$$\hat{P}(x_{k+1} | z_{0:k+1})$$

3. Importance Sampling

$$x(i) \sim q(x)$$

not 1/1223

$$E_p \{ f(x) \} = \int f(x) p(x) dx$$

$$\underbrace{E_q \{ f(x) \}}_{\text{Importance weight}} = E_p \{ f(x) \}$$

Importance weight

$$w(x) = \frac{p(x)}{q(x)}$$

$$q \geq p$$

$$\int f(x) w(x) q(x) dx$$

domination:

if $q=0$ then $p=0$

$$x(i) \sim q(x)$$

$$\frac{1}{n} \sum_{i=1}^n \underbrace{w(x(i)) f(x(i))}_{\text{PES}} \xrightarrow{n \rightarrow \infty} E_q \{ w(x) f(x) \} = E_p \{ f(x) \}$$

$$E_q \{ w(x) \} = \int_{-\infty}^{\infty} w(x) q(x) dx = \int_{-\infty}^{\infty} p(x) dx = 1 \quad x(i) \sim q(x)$$

$$\frac{1}{n} \sum_{i=1}^n w(x(i)) \xrightarrow{n \rightarrow \infty} 1 = E_q \{ w(x) \}$$

$$\sum_{i=1}^n w(x(i)) \approx n$$

$$\tilde{w}(i) = \frac{w(x(i))}{\sum_{j=1}^n w(x(j))} = 1$$

$$\sum_{i=1}^n \tilde{w}_i f(x_i) \xrightarrow{n \rightarrow \infty} E_p \{f(x)\}$$

4. Particle Filtering (sequential monte carlo)

$$\{x_k(i), \tilde{w}_k(i)\}_{i=1}^n \longrightarrow \hat{P}(x_k | z_{0:k}) =$$

$$\sum_{i=1}^n \tilde{w}_k(i) \delta_{x_k(i)}(x_k - x_k^{(i)}) \xrightarrow{n \rightarrow \infty} P(x_k | z_{0:k})$$

a. Time propagation -

$$\hat{P}(x_k | z_{0:k}) \longrightarrow \hat{P}(x_{k+1} | z_{0:k})$$

$$\hat{P}(x_{k+1} | z_{0:k}) = \int_{x_k} P(x_{k+1} | x_k) \hat{P}(x_k | z_{0:k}) dx_k =$$

$$= \sum_{i=1}^n P(x_{k+1} | x_k^{(i)}) \tilde{w}_k(i)$$

$$x_{k+1} = f(x_k) \longrightarrow P(x_{k+1} | x_k) = \delta(x_{k+1} - f(x_k))$$

$$= \sum_{i=1}^n P(x_{k+1} | x_k^{(i)}) \tilde{w}_k(i) = \begin{cases} \tilde{w}_k(i), & x_{k+1} = f(x_k^{(i)}) \\ 0, & \text{Else} \end{cases}$$

b. Sampling -

$$x_{k+1}^{(i)} \stackrel{\text{प्रिय}}{\sim} P(x_{k+1} | x_k^{(i)}; \quad x_k^{(i)} \\ f(x_k, v_k^{(i)}) \rightarrow x_{k+1}^{(i)} \\ v_k^{(i)} \sim P(v_k) \quad \text{वर्तमान} \\ \{x_{k+1}^{(i)}, \tilde{w}_k^{(i)}\} \rightarrow \hat{P}(x_{k+1} | z_{0:k}) = \\ = \sum_{i=1}^n \tilde{w}_k^{(i)} f(x_{k+1} - x_{k+1}^{(i)})$$

$$x_{k+1}^{(i)} = f(x_k^{(i)}, v_k^{(i)}), \quad v_k^{(i)} \sim P(v_k)$$

for $i = 1, \dots, n$

Obtain: $\{x_k, \tilde{w}_k^{(i)}\}$

$$\begin{aligned} \hat{P}(x_{k+1} | z_{0:k+1}) &\propto P(z_{k+1} | x_{k+1}) \hat{P}(x_{k+1} | z_{0:k}) \\ &= P(z_{k+1} | x_{k+1}) \sum_{i=1}^n \tilde{w}_k^{(i)} f(x_{k+1} - x_{k+1}^{(i)}) \\ \hat{P}(x_{k+1}^{(j)} | z_{0:k+1}) &\propto P(z_{k+1} | x_{k+1}^{(j)}) \tilde{w}_k^{(j)} \end{aligned}$$

$$\omega_k = \frac{P(x_k | z_{0:n})}{\sum P(x_k | z_{0:n})},$$

$$\omega_{k+1} = \frac{P(z_{k+1} | x_{k+1}) P(x_{k+1} | x_k) P(x_k | z_{0:n})}{\sum P(x_{k+1} | x_k) P(x_k | z_{0:n})}$$

\$P(x_{k+1} | z_{0:n})\$

$$\omega_{k+1} = P(z_{k+1} | x_{k+1}) \omega_k$$

c. Modellwelt Update

$$\tilde{\omega}_{k+1}^{(i)} = P(z_{k+1} | x_{k+1}^{(i)}) \tilde{\omega}_k^{(i)}, \text{ for } i=1, \dots, n.$$

$$\tilde{\omega}_{k+1}^{(i)} = \frac{\omega_{k+1}^{(i)}}{\sum_{j=1}^n \omega_{k+1}^{(j)}}$$

$$\text{Init: } \{x_0^{(i)}, 1/n\}_{i=1}^n, \quad x_0^{(i)} \sim P(x_0)$$

$$\text{Estimation: } \hat{x}_{k+1} = \sum_{i=1}^n \tilde{\omega}_{k+1}^{(i)} x_{k+1}^{(i)}$$

$$C_{k+1} = \sum_{i=1}^n \tilde{\omega}_{k+1}^{(i)} (x_{k+1}^{(i)} - \hat{x}_{k+1})(\cdot)^T$$

d. Particle degeneracy -

" ω_n " \approx ω_0 \approx ω_1 \dots ω_K \approx ω_{K+1} \dots ω_N

$$P(x_{k+1} | x_k), \omega_k$$

$$\omega_{k+1} = q(x_{k+1} | x_k)$$

$$\omega_k = \prod_{i=1}^K \frac{P(x_{i+1} | x_i)}{q(x_{i+1} | x_i)}, \quad x_0, x_1, \dots, x_k \sim q$$

$$\frac{1}{K} \log \omega_k = \frac{1}{K} \sum_{i=1}^K \log \frac{P(x_i)}{q(x_i)} \longrightarrow$$

$$\xrightarrow[K \rightarrow \infty]{} E_q \left\{ \log \frac{P(x)}{q(x)} \right\} \leq \log E_q \left\{ \frac{P(x)}{q(x)} \right\} = 0$$

if $P \neq q$

$$\frac{1}{K} \log \omega_k \approx -E_q \left\{ \log \frac{q(x)}{P(x)} \right\} \leq 0 \quad (KL = 0 \text{ if } P = q)$$

$KL(q || P)$

$$\omega_k = e^{-K \cdot KL(q || P)} \xrightarrow[K \rightarrow \infty]{} \begin{cases} 0, & P \neq q \\ 1, & P = q \end{cases}$$

e. Resample - ($n_{eff} < \alpha \cdot n$) $\alpha = 2/3$

$$\{x_{k+1}^{(i)}, \tilde{w}_{k+1}^{(i)}\} \xrightarrow{\text{Resample}} x_{k+1}^{(i)} \text{ w.p. } \tilde{w}_{k+1}^{(i)}$$

$$\{ \bar{x}_{k+1}^{(i)}, 1/n \}$$

$$\bar{x}_{k+1}(j+m) = x_{k+1}^{(i)} + \underbrace{z_m}_{\text{noise}} \quad m=0, \dots, \lfloor \tilde{w}_{k+1}^{(i)} \rfloor - 1$$

(זיהוי נסיגת איזון בודד)

$$h_{eff} = \frac{1}{\sum_{i=1}^n \tilde{w}_{k+1}^{(i)2}}$$

PF (SIR)

$$1. \{x_k^{(i)}, \tilde{w}_k^{(i)}\} \xrightarrow{P(x_{k+1}|x_k)} \{x_{k+1}^{(i)}, \tilde{w}_k^{(i)}\}$$

$$2. \{x_{k+1}^{(i)}, \tilde{w}_k^{(i)}\} \xrightarrow{P(z_{k+1}|x_{k+1})} z_{k+1} = h(x_{k+1}) + u_{k+1}$$

$$3. \hat{x}_{k+1} = \sum_{i=1}^n \tilde{w}_{k+1}^{(i)} x_{k+1}^{(i)} = P_{unif}(z_{k+1} - h(x_{k+1}^{(i)}))$$

$$4. h_{eff} = \frac{1}{\sum_{i=1}^n \tilde{w}_{k+1}^{(i)2}}$$

5. if $h_{eff} < 2/3 h$ then Resample: $\{\bar{x}_{k+1}^{(i)}, 1/n\}$

✓ 1/2

8 10'c

Implementation

Sampling / Now .1

SIR PF Resampling .2

Regularized PF .3

Approximate PF for all .4

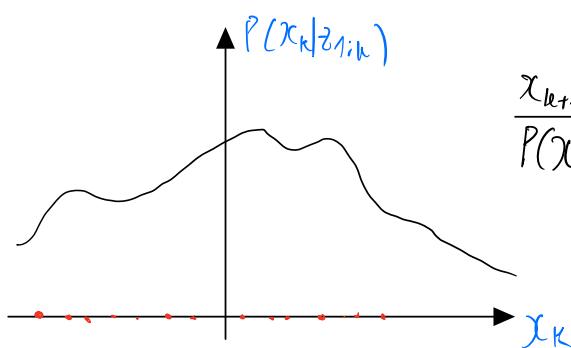
Ratio - Blackwellization .5

Augmented PS .6

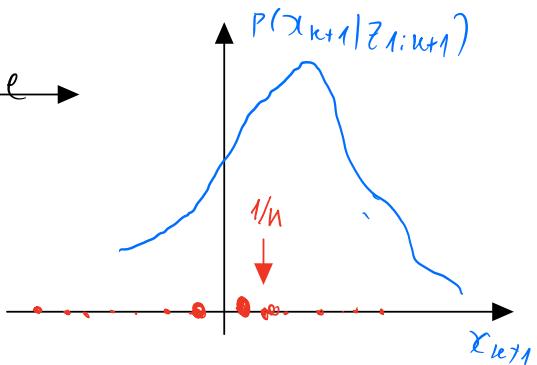
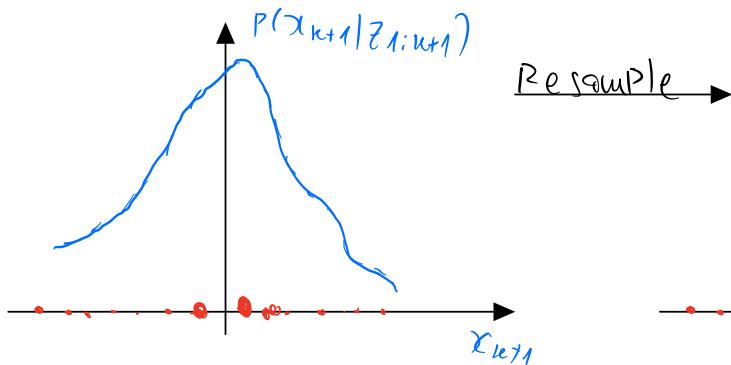
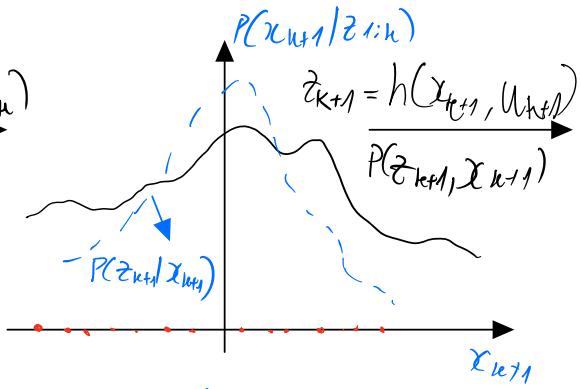
(PF) ~~Sampling~~ . 1

Filtrering density -

$$\hat{P}(x_k | z_{1:k}) = \sum_{i=1}^n \tilde{\omega}_k(i) \cdot \delta(x_k - x_k(i))$$



$$x_{k+1} = f(x_k, w_k)$$

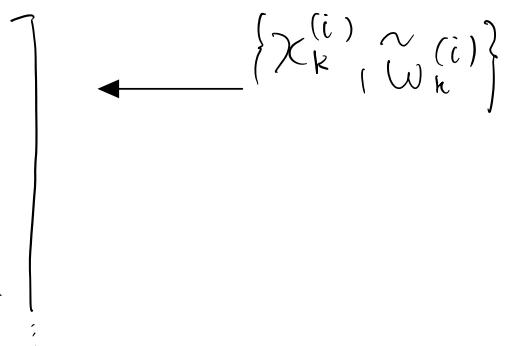


2. SIR-PF Resampling

for $i = 1, \dots, n$

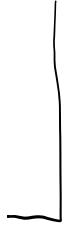
$$m = \lfloor n \tilde{\omega}_k^{(i)} \rfloor$$

$$\bar{x}_k(j+l) = x_k^{(i)}, \quad l = 1, \dots, m$$



$$j \rightarrow j+m$$

$$\{\bar{x}_n^{(i)}, 1/n\}_{i=1}^n$$



3. Regularized-PF

$$\hat{P}_k = \sum_{i=1}^n \tilde{\omega}_k^{(i)} (\bar{x}_n^{(i)} - \hat{x}_n) (\cdot)^T$$

$$\hat{x}_k = \sum_{i=1}^n \bar{\omega}_k^{(i)} x_n^{(i)}$$

$$A = \sqrt{\hat{P}_k^{-1}} \quad (\text{Cholesky})$$

for $i = 1, \dots, n$

$$m = \lfloor n \tilde{\omega}_k^{(i)} \rfloor$$

$$\hat{P}_k = AA^T$$

$$\begin{matrix} \hat{x}_k \\ A \\ \hat{P}_k \end{matrix} \sim N(0, I)$$

$$\bar{x}_n(j+q) = x_n^{(i)} + \mathcal{E} \cdot A \cdot \hat{z}_l, \quad q = 1, \dots, m$$

$$j \rightarrow j+m$$

$$x_0 \sim N(\hat{x}_0, P_0)$$

$$x_{k+1} = A_k x_k + B_k w_k$$

$$w_k \sim U[-\alpha, \alpha]$$

$$u_k \sim N(0, \Sigma)$$

$$z_{k+1} = h(x_{k+1}) + u_{k+1}$$

$z_{1:k}$ known x_k de MME present, $\rho'(z_1^k)$

$$\hat{x}_k = E\{x_k | z_{1:k}\} \approx \hat{E}\{x_k | z_{1:k}\} = \sum_{i=1}^h \tilde{w}_k^{(i)} x_k^{(i)}$$

a. Initialization:

$$x_0^{(i)} \sim N(\hat{x}_0, P_0), \quad i = 1, \dots, h$$

$$\tilde{w}_0^{(i)} = 1/h$$

for $k = 0, \dots$

b. Prediction/Propagation:

$$\{x_k^{(i)}, \tilde{w}_k^{(i)}\} \longrightarrow \{x_{k+1}^{(i)} = A_k x_k^{(i)}, \tilde{w}_{k+1}^{(i)}\}$$

c. if z_{k+1} available:

$$\{x_{k+1}^{(i)}, \tilde{w}_{k+1}^{(i)}\} \rightarrow \{x_{k+1}^{(i)}, \tilde{w}_{k+1}^{(i)} = P(z_{k+1} | x_{k+1}^{(i)}) \tilde{w}_k^{(i)}\}$$

$$N(z_{k+1} - h(x_{k+1}^{(i)}), R) \propto \exp\left\{-\frac{1}{2}(z_{k+1} - \cdot)^T R^{-1} \cdot\right\}$$

d. Compute estimator:

$$\hat{x}_{k+1} = \sum_{i=1}^h \tilde{w}_{k+1}^{(i)} x_{k+1}^{(i)}$$

e. if $N_{eff} = \frac{1}{\sum_i \tilde{w}_{k+1}^{(i)} z_i^2} < \frac{2}{3} n \rightarrow \text{Resample.}$

5. R90 - Blackwellization

$$P(x_k, y_k | z_{1:k}) = \underbrace{P(x_k | y_k, z_{1:k})}_{PF} P(y_k | z_{1:k}) \quad \text{→ Known prior distribution}$$

. 2- \times 10'237 13'5

$$\begin{aligned} P(x_{k+1} | x_k, y_k) &\leftarrow \begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} f_x(x_k, y_k, w_k^x) \\ f_y(x_k) + A y_k + w_k^y \end{bmatrix} \\ P(y_{k+1} | x_k, y_k) &= N(\psi_{k+1} - f_y(\cdot) - A \varphi_x, Q) \quad w_k^y \sim N(0, Q) \end{aligned}$$

$$\begin{aligned} P(z_{k+1}^x | x_{k+1}, y_{k+1}) &\leftarrow \begin{bmatrix} z_{k+1}^x \\ z_{k+1}^y \end{bmatrix} = \begin{bmatrix} h^x(x_{k+1}, y_{k+1}) + u_{k+1}^x \\ h^y(x_{k+1}) + h\psi_{k+1} + u_{k+1}^y \end{bmatrix} \\ P(z_{k+1}^y | x_{k+1}, y_{k+1}) &= N(z_{k+1}^y - h^y(x_{k+1}) - h\psi_{k+1}, R) \end{aligned}$$

13'0 13'.6

$$P(z_{k+1} | z_{1:k}) = \text{evidence}$$

$$= \int_{x_{k+1}} P(z_{k+1} | x_{k+1}) P(x_{k+1} | z_{1:k}) dx_{k+1} \approx$$

$$\approx \sum_{i=1}^n \tilde{\omega}_k^{(i)} \underbrace{P(z_{k+1} | x_{k+1}^{(i)})}_{\exp \left\{ -\frac{1}{2} \left(z_{k+1}^{(i)} - x_{k+1}^{(i)} - D(x_{k+1}^{(i)}) R^w \right)^T R^{-1}(\cdot) \right\}} < \epsilon$$

$$\approx \sum_{i=1}^n \tilde{\omega}_k^{(i)} \hat{x}_{k+1}^{(i)}$$

$$\approx P(z_{k+1} | \hat{x}_{k+1})$$

$$P\left(\begin{bmatrix} x_k \\ y_k \end{bmatrix} | z_{1:k}\right) = P(x_k | y_k, z_{1:k}) P(y_k | z_{1:k})$$

$$\approx P(x_k | \hat{y}_k, z_{1:k}) P(y_k | \hat{x}_k, z_{1:k})$$

